



**Universidad  
de Alcalá**

# **TRABAJO DE FIN DE GRADO**

**GRADO EN ECONOMÍA**

**FACULTAD DE CIENCIAS ECONÓMICAS, EMPRESARIALES Y  
TURISMO**

**Modelos estadísticos clásicos y avanzados. Aplicación al  
credit scoring utilizando Modelos Lineales Generalizados,  
SMOTE y Árboles de Decisión**

**MARC BAGUR VIZOSO**

**Tutor: DAVID ATANCE DEL OLMO**

**2025/2026**

# Modelos estadísticos clásicos y avanzados. Aplicación al credit scoring utilizando Modelo Lineales Generalizados, Smote y Árboles de Decisión.

Marc Bagur Vizoso<sup>a</sup>

<sup>a</sup> Departamento de Economía y Dirección de Empresas, Universidad de Alcalá, Madrid, España.  
Supervisado por David Atance

9 de septiembre de 2026

## Resumen

El análisis del riesgo crediticio constituye una actividad fundamental para las instituciones financieras, ya que permite estimar la probabilidad de impago de los prestatarios y apoyar las decisiones de concesión de crédito. En este contexto, los sistemas de credit scoring se han utilizado ampliamente para clasificar a las personas que solicitan préstamos según su nivel de riesgo, a partir de información financiera y sociodemográfica. Tradicionalmente, los modelos estadísticos como la regresión logística han sido las herramientas predominantes debido a su robustez, capacidad predictiva y facilidad de interpretación. No obstante, la creciente disponibilidad de datos y el desarrollo de técnicas de aprendizaje automático han ampliado las posibilidades metodológicas para abordar este tipo de problemas. El presente trabajo analiza la aplicación de modelos lineales generalizados (GLM), específicamente las especificaciones **logit** y **probit**, para estimar la probabilidad de impago en un contexto de credit scoring. Asimismo, se aborda uno de los principales desafíos de este tipo de aplicaciones: la existencia de conjuntos de datos desbalanceados, en los que los casos de impago representan una proporción reducida de las observaciones. Para tratar este problema se aplica la técnica de sobremuestreo sintético de minorías (SMOTE), con el fin de mejorar la capacidad de clasificación de los modelos. El análisis empírico se basa en la estimación y comparación de diferentes especificaciones, evaluando su rendimiento predictivo tanto dentro como fuera de la muestra. Los resultados obtenidos permiten valorar la utilidad de estas metodologías para la modelización del riesgo crediticio y contribuyen a comprender el impacto de las técnicas de balanceo de datos en el desempeño de los modelos de scoring.

**Palabras clave:** GLM; Probit; Logit; SMOTE; Dentro de la muestra; Fuera de la muestra.

## Abstract

Credit risk assessment is a fundamental activity for financial institutions, as it enables the estimation of borrowers' probability of default and supports lending decisions. In this context, credit scoring systems have been widely used to classify applicants according to their level of risk using financial and sociodemographic information. Traditionally, statistical models such as logistic regression have been the dominant tools due to their robustness, predictive performance, and interpretability. However, the growing availability of data and the development of machine learning techniques have expanded the methodological possibilities for addressing these problems. This paper analyzes the application of Generalized Linear Models (GLMs), specifically the `logit` and `probit` specifications, to estimate the probability of default in a credit scoring framework. In addition, the study addresses one of the main challenges present in this type of application: the existence of imbalanced datasets, in which default cases represent a relatively small proportion of the observations. To address this issue, we apply machine learning techniques such as the Synthetic Minority Over-sampling Technique (SMOTE), with the aim of improving the classification performance of the models. The empirical analysis is based on the estimation and comparison of different model specifications, evaluating their predictive performance both in-sample and out-of-sample. The results provide insights into the usefulness of these methodologies for credit risk modeling and contribute to understanding the impact of data balancing techniques on the performance of credit scoring models.

**Keywords:** GLMs; Probit; Logit; SMOTE; In-sample; Out-of-sample.

# Índice

|                                                                                                   |           |
|---------------------------------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                                            | <b>8</b>  |
| <b>2. El credit scoring y la medición del riesgo crediticio</b>                                   | <b>10</b> |
| 2.1. Objetivo de los modelos de credit scoring . . . . .                                          | 10        |
| 2.2. Medidas utilizadas en este trabajo . . . . .                                                 | 11        |
| <b>3. Modelos lineales generalizados y distribución binomial: especificaciones logit y probit</b> | <b>12</b> |
| 3.1. Modelos lineales generalizados . . . . .                                                     | 12        |
| 3.2. Distribución binomial en modelos de riesgo crediticio . . . . .                              | 13        |
| 3.3. Modelos logit . . . . .                                                                      | 13        |
| 3.4. Modelo probit . . . . .                                                                      | 14        |
| <b>4. Selección de variables: métodos Forward y Backward Stepwise</b>                             | <b>15</b> |
| 4.1. Problema de sobreajuste <i>overfitting</i> . . . . .                                         | 15        |
| 4.2. Medidas de evaluación y selección de modelos . . . . .                                       | 16        |
| 4.3. Método Forward Stepwise . . . . .                                                            | 17        |
| 4.4. Método Backward Stepwise . . . . .                                                           | 18        |
| 4.5. Aplicación de los métodos stepwise en este trabajo . . . . .                                 | 19        |
| <b>5. Datos desbalanceados y técnica SMOTE</b>                                                    | <b>19</b> |
| 5.1. Datos desbalanceados en credit scoring . . . . .                                             | 20        |
| 5.2. Técnicas para tratar datos desbalanceados . . . . .                                          | 20        |
| 5.3. Synthetic Minority Over-sampling Technique (SMOTE) . . . . .                                 | 21        |
| 5.4. Ventajas y limitaciones del método . . . . .                                                 | 21        |
| <b>6. Modelos de aprendizaje automático: Random Forest</b>                                        | <b>22</b> |
| 6.1. Árboles de decisión y métodos de ensamble . . . . .                                          | 22        |
| 6.2. El algoritmo Random Forest . . . . .                                                         | 23        |
| 6.3. Ventajas y limitaciones en el contexto del credit scoring . . . . .                          | 25        |
| 6.4. Combinación con técnicas de tratamiento del desbalance . . . . .                             | 26        |
| <b>7. Aplicación práctica</b>                                                                     | <b>27</b> |
| 7.1. Datos y tratamiento de la información . . . . .                                              | 27        |
| 7.1.1. Construcción de la variable dependiente (Default) . . . . .                                | 29        |
| 7.1.2. Limpieza inicial del dataset . . . . .                                                     | 31        |
| 7.1.3. Eliminación de variables no relevantes . . . . .                                           | 33        |
| 7.1.4. Transformación de variables explicativas . . . . .                                         | 34        |
| 7.1.5. Limpieza avanzada de datos . . . . .                                                       | 37        |
| 7.1.6. Definición del conjunto de variables explicativas . . . . .                                | 38        |
| 7.1.7. Análisis exploratorio de los datos . . . . .                                               | 39        |
| 7.1.8. Análisis de correlación . . . . .                                                          | 40        |
| 7.2. Bondad de ajuste, diseño de validación y métricas de evaluación . . . . .                    | 44        |
| <b>8. Estimación de modelos y análisis de resultados</b>                                          | <b>46</b> |
| 8.1. GLM: logit y probit . . . . .                                                                | 46        |
| 8.2. SMOTE y Random Forest . . . . .                                                              | 49        |
| 8.3. Aplicación práctica de los diferentes modelos . . . . .                                      | 49        |
| 8.3.1. Ajuste dentro de muestra . . . . .                                                         | 49        |

|           |                                                |           |
|-----------|------------------------------------------------|-----------|
| 8.3.2.    | Rendimiento visual dentro de muestra . . . . . | 50        |
| 8.3.3.    | Capacidad predictiva de los modelos . . . . .  | 52        |
| <b>9.</b> | <b>Conclusiones</b>                            | <b>55</b> |

## Índice de cuadros

|     |                                                                                      |    |
|-----|--------------------------------------------------------------------------------------|----|
| 1.  | Resumen de algunas variables relevantes utilizadas en el análisis . . . . .          | 28 |
| 2.  | Dimensiones del conjunto de datos tras el proceso de limpieza y transformación       | 29 |
| 3.  | Escenarios considerados para la construcción de la variable <b>default</b> . . . . . | 30 |
| 4.  | Tasa de impago y proporción de préstamos vigentes por año de originación             | 31 |
| 5.  | Variables con mayor porcentaje de valores faltantes . . . . .                        | 32 |
| 6.  | Tratamiento de valores faltantes . . . . .                                           | 33 |
| 7.  | Codificación ordinal de la variable <b>IncomeRange</b> . . . . .                     | 36 |
| 8.  | Pares de variables con correlación fuerte ( $ r  \geq 0.7$ ) . . . . .               | 43 |
| 9.  | Variables, coeficientes, odds ratios y p-valores del modelo Logit Forward . .        | 48 |
| 10. | Ajuste de los siete modelos en la muestra de entrenamiento . . . . .                 | 50 |
| 11. | Capacidad predictiva de los siete modelos en la muestra de prueba . . . . .          | 52 |
| 12. | Trade-off entre modelos . . . . .                                                    | 55 |

## Índice de figuras

|     |                                                                                                                                                                                                                                                                   |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.  | Esquema del procedimiento <i>forward stepwise</i> . . . . .                                                                                                                                                                                                       | 18 |
| 2.  | Esquema del procedimiento <i>backward stepwise</i> . . . . .                                                                                                                                                                                                      | 19 |
| 3.  | Funcionamiento del algoritmo SMOTE mediante interpolación entre observaciones de la clase minoritaria. . . . .                                                                                                                                                    | 21 |
| 4.  | Esquema de funcionamiento del algoritmo Random Forest . . . . .                                                                                                                                                                                                   | 23 |
| 5.  | Esquema del procedimiento de cálculo de la importancia relativa de las variables en Random Forest . . . . .                                                                                                                                                       | 25 |
| 6.  | Distribución de variables numéricas seleccionadas. (a) <code>LoanOriginalAmount</code> ; (b) <code>BorrowerRate</code> ; (c) <code>BorrowerAPR</code> ; (d) <code>ProsperScore</code> ; (e) <code>DebtToIncomeRatio</code> ; (f) <code>FICOScore</code> . . . . . | 39 |
| 7.  | Matriz inicial de correlaciones . . . . .                                                                                                                                                                                                                         | 41 |
| 8.  | Matriz de correlación ordenada mediante clustering . . . . .                                                                                                                                                                                                      | 42 |
| 9.  | Matriz de correlación de las variables con $ r  \geq 0.7$ . . . . .                                                                                                                                                                                               | 42 |
| 10. | Matriz de correlación tras eliminación de variables . . . . .                                                                                                                                                                                                     | 44 |
| 11. | Curvas ROC de los siete modelos en la muestra de entrenamiento . . . . .                                                                                                                                                                                          | 51 |
| 12. | Matrices de confusión de los siete modelos en la muestra de entrenamiento . . . . .                                                                                                                                                                               | 51 |
| 13. | Curvas ROC de los siete modelos en la muestra de prueba . . . . .                                                                                                                                                                                                 | 53 |
| 14. | Matrices de confusión de los siete modelos en la muestra de prueba . . . . .                                                                                                                                                                                      | 53 |
| 15. | Comparación de ROC-AUC entre modelos en la muestra de prueba . . . . .                                                                                                                                                                                            | 54 |
| 16. | Comparación de <i>recall</i> entre modelos en la muestra de prueba . . . . .                                                                                                                                                                                      | 54 |

# 1. Introducción

Asumir y gestionar riesgos forma parte del núcleo mismo de la actividad bancaria. Durante los últimos años, además, la incertidumbre del escenario económico internacional ha aumentado de manera notable: pandemias, tensiones geopolíticas, subidas de los tipos de interés y episodios de desaceleración se han sucedido en un intervalo relativamente corto. Cuando estos factores deterioran la solvencia de quienes han recibido financiación, las entidades ven crecer su exposición al riesgo de crédito. De ahí que identificar, cuantificar y anticipar ese riesgo con instrumentos rigurosos haya pasado a ocupar un lugar prioritario tanto en la estrategia bancaria como en la agenda regulatoria (Kumar and Gunjan, 2020; Shi et al., 2022).

Medir el riesgo de crédito es, por tanto, una de las funciones estructurales del sistema financiero. Bancos y demás intermediarios resuelven a diario operaciones de financiación en las que deben anticipar si el solicitante atenderá o no sus compromisos de pago. Para sistematizar esa decisión se recurre al credit scoring, que ordena a los solicitantes por nivel de riesgo y traslada la concesión de crédito a criterios cuantitativos y homogéneos (Abdou and Pointon, 2011).

Durante décadas, la construcción de estos sistemas se apoyó en técnicas estadísticas de complejidad moderada, entre las que ocupa un lugar destacado la regresión logística formalizada por Cox (1958), junto a otros procedimientos de clasificación binaria. Todos ellos pertenecen a la familia de los Modelos Lineales Generalizados (GLM), cuyo planteamiento consiste en vincular la variable respuesta con los regresores a través de una función de enlace escogida según la naturaleza de aquella (Hastie et al., 2009). Esa combinación de flexibilidad, fundamento teórico y facilidad de lectura de los resultados explica su implantación en campos aplicados muy diversos (James et al., 2023). Trasladados al credit scoring, los GLM devuelven una probabilidad de impago condicionada a los rasgos financieros, laborales o demográficos del solicitante (Nelder and Wedderburn, 1972; Dong et al., 2010).

El panorama, sin embargo, se ha ampliado de forma considerable con el avance del machine learning y con el acceso a bases de datos de mayor tamaño y granularidad. Alternativas más flexibles, como los árboles CART<sup>1</sup>, las técnicas de ensamble<sup>2</sup> o las redes neuronales<sup>3</sup>, superan con frecuencia el poder predictivo de la modelización estadística clásica (Breiman et al., 1984; Bishop, 1995; Breiman, 2001; Brown and Mues, 2012). La contrapartida es una menor transparencia: el mecanismo que conduce de los datos a la puntuación resulta difícil de explicitar, algo problemático en un sector donde el supervisor exige que las decisiones de crédito puedan justificarse.

Por esa razón los GLM no han sido desplazados del análisis del riesgo de crédito. Las especificaciones **logit** y **probit** se ajustan bien a variables dependientes dicotómicas como la que aquí interesa, el impago, y sitúan al analista en un punto intermedio razonable entre

---

<sup>1</sup>Los árboles de decisión segmentan el conjunto de datos utilizando reglas sucesivas de categorización de las variables, buscando generar grupos homogéneos respecto a la variable objetivo. El método CART (Classification and Regression Trees) fue propuesto por Breiman et al. (1984).

<sup>2</sup>Los modelos de ensamble combinan varios modelos base con el objetivo de mejorar la precisión predictiva y reducir la varianza o el sesgo del estimador. Entre los enfoques más utilizados destacan el *bagging*, el *random forest* y el *boosting* (Breiman, 2001).

<sup>3</sup>Las redes neuronales artificiales están formadas por capas de nodos interconectados que aprenden patrones complejos y relaciones no lineales a partir de los datos mediante procesos iterativos de entrenamiento (Bishop, 1995).

precisión predictiva, rigor estadístico y lectura económica de los coeficientes; de ahí su uso extendido en credit scoring.

Un segundo obstáculo, de naturaleza distinta, aparece cuando las dos categorías de la variable objetivo están repartidas de forma muy desigual. En las carteras crediticias reales los préstamos impagados suelen ser una fracción reducida del total, y un clasificador entrenado sobre esa distribución tiende a acertar por defecto en la categoría abundante mientras falla precisamente en los expedientes que interesa detectar (He and Garcia, 2009). Frente a ello se han propuesto diversos procedimientos de remuestreo, entre los que ha alcanzado mayor difusión la *Synthetic Minority Over-sampling Technique* (SMOTE) de Chawla et al. (2002): en lugar de duplicar registros, genera observaciones artificiales de la clase escasa por interpolación, con el propósito de que el modelo aprenda mejor sus patrones.

Sobre estos dos ejes se construye el presente trabajo. Su propósito general es examinar el comportamiento de los GLM en un problema de credit scoring y contrastarlos con alternativas de machine learning, incorporando además el tratamiento del desbalance mediante SMOTE. Concretamente, se estiman modelos con enlace **logit** y **probit** y se depura el conjunto de regresores mediante procedimientos secuenciales *forward* y *backward stepwise*, que incorporan variables una a una o las eliminan partiendo del modelo completo, conservando únicamente aquellas estadísticamente significativas. La comparación final del rendimiento se realiza tanto sobre los datos empleados en la estimación como sobre observaciones reservadas (James et al., 2021).

Este propósito se descompone en cuatro objetivos específicos. El primero es definir, con criterio metodológico explícito, la variable de impago a partir del estado final registrado para cada préstamo, y dejar la base preparada para el tratamiento econométrico. El segundo, estimar las especificaciones **logit** y **probit** bajo distintos procedimientos de selección secuencial y comprobar hasta qué punto el conjunto de predictores resultante es estable. El tercero, medir en qué grado SMOTE altera la capacidad del modelo para señalar los casos de impago. El cuarto, determinar si un método no paramétrico como Random Forest mejora lo suficiente la predicción como para justificar la interpretabilidad que se pierde.

A ellos se asocian tres hipótesis de trabajo. La primera es que **logit** y **probit** rendirán de forma prácticamente indistinguible, dada la proximidad formal de ambas funciones de enlace. La segunda, que aplicar SMOTE elevará de manera apreciable la proporción de impagos detectados, aunque penalizando la precisión y el acierto global. La tercera, que la ventaja predictiva del aprendizaje automático sobre los modelos lineales será modesta, de manera que la elección entre uno y otro enfoque responderá al criterio de decisión que se adopte y no al dominio de una métrica aislada.

El documento se organiza como sigue. La sección 2 revisa el concepto de credit scoring y las formas habituales de medir el riesgo de crédito. La sección 3 presenta el marco de los GLM y las especificaciones **logit** y **probit**. La sección 4 detalla los métodos de selección de variables aplicados y la sección 5 desarrolla el fundamento de SMOTE. La sección 6 introduce Random Forest como término de comparación frente a los modelos lineales. La aplicación empírica, con la descripción de los datos y de la metodología, se recoge en la sección 7, mientras que la sección 8 reúne los resultados dentro y fuera de muestra. La sección 9 cierra con las conclusiones.

## 2. El credit scoring y la medición del riesgo crediticio

Un sistema de credit scoring persigue un objetivo acotado: asignar a cada prestatario la probabilidad de que incumpla sus compromisos de pago dentro de un horizonte temporal previamente fijado. El valor de esa estimación es operativo. Con ella, la entidad ordena a los solicitantes por nivel de riesgo y dispone de un fundamento cuantitativo para tres decisiones distintas: conceder o denegar la operación, fijar las condiciones del contrato y gestionar la composición de su cartera (Thomas, 2009; Abdou and Pointon, 2011).

En el plano normativo, la medición del riesgo de crédito ocupa una posición destacada dentro del marco prudencial que se aplica a las entidades financieras. Los acuerdos de Basel Committee on Banking Supervision (2006, 2017) (Basilea II y Basilea III) exigen que los bancos cuenten con metodologías internas solventes para cuantificar las pérdidas que podrían derivarse del incumplimiento de sus prestatarios y para sostener un nivel de capital acorde con el riesgo que asumen. La articulación habitual descansa en tres parámetros: la probabilidad de impago (*Probability of Default, PD*), la severidad de la pérdida una vez producido el incumplimiento (*Loss Given Default, LGD*) y el saldo expuesto en ese momento (*Exposure at Default, EAD*), cuya combinación proporciona la pérdida esperada y, a partir de ella, los requerimientos regulatorios de capital. La propia normativa añade condiciones sobre los modelos empleados: han de ser robustos, trazables, validados con periodicidad y comprensibles para quien los supervise o audite (Basel Committee on Banking Supervision, 2006, 2017; European Union, 2024a,b).

En esencia, un modelo de scoring resume en una cifra el riesgo que comporta cada solicitud. Esa cifra se obtiene combinando la información conocida del solicitante, sea este particular o empresa: magnitudes financieras, atributos demográficos y antecedentes de comportamiento crediticio. El resultado, expresado como puntuación o como probabilidad, permite ordenar a los individuos según su riesgo relativo de impago (Shi et al., 2022).

La difusión de estos modelos en la industria financiera se explica por dos motivos principales: agilizan la toma de decisiones y abaratan un proceso que, realizado manualmente, resulta costoso. A ello se suma que homogeneizan los criterios de concesión y limitan el margen de discrecionalidad del analista al valorar cada expediente (Finlay, 2012).

El uso de estos sistemas no se limita, además, a separar solicitantes solventes de insolventes. Intervienen igualmente en la fijación del precio del crédito bajo esquemas de *risk-based pricing*, según los cuales el tipo de interés, las comisiones y el límite concedido varían con el riesgo estimado del solicitante. Un perfil con baja probabilidad de impago obtiene condiciones más favorables, mientras que uno de riesgo elevado soporta una prima que compensa a la entidad por la exposición asumida (Experian Decision Analytic, 2026).

### 2.1. Objetivo de los modelos de credit scoring

Lo que persigue un sistema de credit scoring es cuantificar la probabilidad de impago (*probability of default, PD*) de un solicitante empleando únicamente información conocida en el momento previo a la concesión. Para ello rastrea en el historial disponible las regularidades que separan a quienes atendieron sus compromisos de quienes acabaron en situación de insolvencia (Abdou and Pointon, 2011).

De esa capacidad para separar unos perfiles de otros depende buena parte de la gestión del riesgo. Cuando la probabilidad de impago se estima con exactitud, según Thomas (2009),

la entidad financiera está en condiciones de:

- Reducir las pérdidas asociadas a créditos incobrables.
- Asignar de forma más eficiente el capital regulatorio.
- Mejorar la rentabilidad de las carteras de crédito mediante políticas de risk-based pricing.
- Satisfacer las exigencias que el supervisor impone en materia de riesgo.

Formalmente, el ejercicio consiste en estimar, para cada solicitante y a partir de sus características observadas, la probabilidad de que incumpla. Esa cifra ordena después a los candidatos por riesgo y sostiene la decisión última de conceder o denegar la operación. Sobre este esquema se han ensayado modelos estadísticos de muy diversa naturaleza (Dastile et al., 2020).

## 2.2. Medidas utilizadas en este trabajo

La variable objetivo de este trabajo es la probabilidad de impago, construida sobre un indicador binario que separa a los prestatarios cumplidores de los que incurren en incumplimiento. Se sigue con ello el planteamiento habitual en la literatura, que trata el credit scoring como un ejercicio de clasificación en dos categorías (Abdou and Pointon, 2011).

Dicha probabilidad se estima mediante GLM, en las especificaciones `logit` y `probit`. Ambas vinculan los regresores con el riesgo estimado de incumplimiento a través de una función de enlace apropiada para respuestas dicotómicas, y devuelven coeficientes que admiten lectura directa en términos de la probabilidad de impago. A ello se añade una consideración práctica: su estructura es sencilla y auditable, algo que no siempre puede decirse de los algoritmos de aprendizaje automático y que pesa en un sector sometido a supervisión como el financiero (Dong et al., 2010).

Conviene advertir, sin embargo, de una particularidad de los datos crediticios: las dos categorías de la variable dependiente rara vez tienen un peso comparable, pues los prestatarios cumplidores superan con holgura a los incumplidores. El desequilibrio condiciona tanto la estimación como la lectura posterior de los resultados, ya que un algoritmo que se apoye en la categoría abundante rendirá peor justamente sobre la escasa, que es la relevante desde la óptica del riesgo.

PEl trabajo recurre a SMOTE (Synthetic Minority Over-sampling Technique) para corregir ese desequilibrio en la fase de preprocesamiento. El procedimiento construye registros artificiales de la categoría escasa tomando como base los ya observados, hasta igualar aproximadamente el peso de ambas clases en la muestra de entrenamiento (Chawla et al., 2002). Lo que interesa contrastar es si ese reequilibrio se traduce en una detección más fiable de los prestatarios con riesgo elevado.

La comparación empírica se plantea, por tanto, entre modelos GLM estimados sobre la muestra original y modelos estimados tras aplicar SMOTE. El objetivo no es comparar un amplio conjunto de algoritmos de machine learning, sino analizar si una técnica de tratamiento del desbalance puede mejorar el rendimiento de modelos estadísticos tradicionales ampliamente utilizados en credit scoring. Las métricas concretas empleadas para dicha comparación se detallan en el apartado 7.2.

El diseño metodológico consta así de tres fases. Se estiman primero las especificaciones **logit** y **probit**, que representan el enfoque estadístico clásico del credit scoring. Se reestiman después sobre una muestra reequilibrada con SMOTE. Y se confrontan finalmente unos y otros mediante indicadores que informan del acierto predictivo, del poder discriminante y de la utilidad del modelo a la hora de ordenar el riesgo crediticio.

### 3. Modelos lineales generalizados y distribución binomial: especificaciones logit y probit

Los modelos de credit scoring suelen formularse como problemas de clasificación binaria en los que el objetivo es estimar la probabilidad de que un prestatario incurra en impago (Thomas, 2009). En este contexto, los modelos lineales generalizados (Generalized Linear Models, GLMs) constituyen una de las herramientas más utilizadas para modelizar variables dependientes binarias, ya que permiten relacionar la probabilidad de ocurrencia de un evento con un conjunto de variables explicativas mediante una función de enlace adecuada (McCullagh and Nelder, 1989).

En aplicaciones de riesgo crediticio, los GLMs permiten estimar directamente la probabilidad de impago a partir de las características observadas de los solicitantes de crédito. Entre las diferentes especificaciones disponibles dentro de esta familia de modelos, las más utilizadas en la literatura son los modelos **logit** y **probit**, los cuales han sido ampliamente aplicados en el análisis del riesgo crediticio debido a su capacidad predictiva y a su relativa facilidad de interpretación (Dong et al., 2010; Abdou and Pointon, 2011).

#### 3.1. Modelos lineales generalizados

Los modelos lineales generalizados extienden el marco de los modelos lineales clásicos permitiendo que la variable dependiente siga distribuciones distintas de la normal. En lugar de modelizar directamente la variable dependiente, los GLMs establecen una relación entre una función de la esperanza de la variable dependiente y una combinación lineal de variables explicativas (McCullagh and Nelder, 1989).

De forma general, un modelo lineal generalizado puede expresarse como:

$$g(\mathbb{E}[Y | X]) = X\beta \quad , \quad (1)$$

donde:

- $Y$  es la variable dependiente,
- $X$  es el vector de variables explicativas, que van a tratar de explicar la variable dependiente.
- $\beta$  representa el vector de parámetros a estimar,
- $g(\cdot)$  es la función de enlace que conecta la media de la variable dependiente con el predictor lineal.

En el caso del credit scoring, la variable dependiente suele ser binaria, indicando si un individuo ha incurrido o no en el impago. Por tanto, resulta natural asumir que esta variable sigue una distribución binomial, lo que conduce a la utilización de funciones de enlace específicas como el **logit** o el **probit**.

### 3.2. Distribución binomial en modelos de riesgo crediticio

En los modelos de riesgo crediticio, la variable dependiente suele tomar únicamente dos valores posibles: por ejemplo, 1 si el prestatario incurre en impago y 0 en caso contrario. Esta estructura se corresponde con una variable aleatoria de naturaleza binaria que puede modelizarse mediante una distribución binomial.

En este contexto, el objetivo del modelo consiste en estimar la probabilidad condicional de impago dada la información disponible sobre el prestatario:

$$\mathbb{P}(Y = 1 \mid X) = p(X) \quad , \quad (2)$$

donde  $p(X)$  representa la probabilidad de que el prestatario incurra en impago dadas sus características observadas.

Sin embargo, modelizar directamente esta probabilidad mediante una combinación lineal de variables explicativas puede generar predicciones fuera del intervalo  $[0, 1]$ . Para evitar este problema, los modelos **logit** o el **probit** utilizan funciones de enlace que transforman la probabilidad en una variable no acotada, permitiendo así aplicar técnicas de estimación basadas en máxima verosimilitud.

### 3.3. Modelos logit

El modelo **logit** es uno de los enfoques más utilizados en el ámbito del credit scoring. En este modelo, la función de enlace utilizada es el logaritmo de la razón de probabilidades (**log-odds**). De este modo, la relación entre la probabilidad de impago y las variables explicativas se expresa como:

$$\log \left( \frac{p(X)}{1 - p(X)} \right) = X\beta = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n \quad . \quad (3)$$

A partir de esta especificación, la probabilidad de impago puede escribirse como:

$$p(X) = \frac{1}{1 + e^{-X\beta}} = \frac{e^{X\beta}}{1 + e^{X\beta}} \quad (4)$$

Además, el modelo **logit** permite interpretar fácilmente el efecto de las variables explicativas sobre el riesgo de impago mediante los denominados **odds ratios**. Estos indican cómo varían las probabilidades relativas de impago cuando una variable explicativa aumenta una unidad, manteniendo constantes el resto de factores. Esta característica facilita la comprensión e interpretación económica de los resultados obtenidos.

Debido a estas características, la regresión logística ha sido históricamente uno de los modelos más utilizados en el desarrollo de scorecards de crédito, es decir, sistemas de puntuación que asignan una calificación o puntuación de riesgo a cada solicitante en función de sus características financieras y personales. Estas herramientas permiten estimar la probabilidad de impago y constituyen uno de los mecanismos más utilizados por las entidades financieras para apoyar sus decisiones de concesión de crédito (Dong et al., 2010; Abdou and Pointon, 2011).

### 3.4. Modelo probit

El modelo **probit** constituye una alternativa al modelo **logit** dentro de la familia de modelos de respuesta binaria. Al igual que la regresión logística, su objetivo es estimar la probabilidad de que ocurra un determinado evento, en este caso el impago del prestatario. Sin embargo, a diferencia del modelo **logit**, el modelo **probit** utiliza como función de enlace la función de distribución acumulada de una normal estándar.

Conceptualmente, el modelo **probit** puede formularse a partir de una variable latente no observada  $Y_i^*$ , que recoge la propensión del prestatario  $i$  a incurrir en impago. Esta variable latente se expresa como una combinación lineal de las variables explicativas:

$$Y_i^* = X_i\beta + \varepsilon_i \quad (5)$$

donde  $X_i\beta = \beta_0 + \beta_1 X_{1i} + \dots + \beta_n X_{ni}$ , y  $\varepsilon_i$  es un término de error que se asume distribuido según una normal estándar. El evento observado de impago se define a partir de dicha variable latente de la siguiente forma:

$$Y_i = \begin{cases} 1 & \text{si } Y_i^* > 0 \\ 0 & \text{si } Y_i^* \leq 0 \end{cases} \quad (6)$$

A partir de esta especificación, la probabilidad de impago puede expresarse como:

$$P(Y_i = 1 \mid X_i) = P(Y_i^* > 0 \mid X_i) \quad (7)$$

Sustituyendo la expresión de la variable latente:

$$P(Y_i = 1 \mid X_i) = P(X_i\beta + \varepsilon_i > 0) \quad (8)$$

lo que equivale a:

$$P(Y_i = 1 \mid X_i) = P(\varepsilon_i > -X_i\beta) \quad (9)$$

Dado que el término de error sigue una distribución normal estándar, esta probabilidad puede escribirse mediante la función de distribución acumulada de dicha distribución:

$$P(Y_i = 1 \mid X_i) = \Phi(X_i\beta) \quad (10)$$

donde  $\Phi(\cdot)$  representa la función de distribución acumulada de una variable aleatoria normal estándar. De este modo, el modelo **probit** transforma la combinación lineal de variables explicativas en una probabilidad comprendida entre 0 y 1.

En la práctica, los modelos **logit** y **probit** suelen producir resultados muy similares en términos de capacidad predictiva, ya que ambos modelos utilizan funciones de enlace con

forma sigmoide<sup>4</sup>. La elección entre uno u otro suele basarse en criterios de conveniencia analítica, tradición dentro del campo de estudio o supuestos sobre la distribución del término de error (Greene, 2012).

## 4. Selección de variables: métodos Forward y Backward Stepwise

En la construcción de modelos credit scoring mediante GLM, la selección de variables constituye un paso fundamental del proceso de modelización. Las bases de datos utilizadas en este tipo de aplicaciones suelen contener un número elevado de variables explicativas potenciales, muchas de las cuales pueden ser irrelevantes o aportar información redundante al modelo. La inclusión de un número excesivo de variables puede generar modelos innecesariamente complejos y reducir su capacidad de generalización a nuevas observaciones (Hastie et al., 2009).

Los procedimientos de selección secuencial de variables constituyen una de las estrategias más utilizadas para construir modelos parsimoniosos cuando se dispone de un número elevado de variables explicativas. Su objetivo es identificar un subconjunto de variables que mantenga una adecuada capacidad predictiva, evitando incorporar información redundante o poco relevante (James et al., 2013).

Entre los métodos más utilizados destacan los procedimientos *forward stepwise* y *backward stepwise*, ambos formulados originalmente por Efroymson (1960). El método *forward* comienza con un modelo vacío e incorpora progresivamente aquellas variables que aportan una mejora significativa según un criterio previamente definido. Por el contrario, el método *backward* parte de un modelo completo y elimina sucesivamente las variables con menor contribución explicativa.

Estos procedimientos permiten automatizar parcialmente el proceso de selección de variables, reduciendo el coste computacional y evitando la necesidad de evaluar manualmente un gran número de especificaciones alternativas. Por este motivo, han sido ampliamente utilizados en los procesos de selección de variables dentro de la modelización estadística (Hastie et al., 2009; James et al., 2013).

Los procedimientos de selección secuencial fueron introducidos por Efroymson (1960) dentro de la literatura clásica de selección de modelos estadísticos y continúan utilizándose como herramientas prácticas para la construcción de modelos predictivos parsimoniosos (Draper and Smith, 1998; Hastie et al., 2009).

### 4.1. Problema de sobreajuste *overfitting*

Uno de los principales riesgos al construir modelos estadísticos es el fenómeno conocido como sobreajuste o *overfitting*. Este problema ocurre cuando el modelo se ajusta excesivamente a los datos utilizados en su estimación, capturando no solo las relaciones estructurales presentes en los datos, sino también el ruido aleatorio.

---

<sup>4</sup>Una función sigmoide es una función monótona creciente con forma de S que transforma cualquier valor real en el intervalo  $(0, 1)$ . Esta propiedad es la que permite convertir el predictor lineal  $X\beta$ , que no está acotado, en una probabilidad válida. Tanto la función logística empleada en el modelo **logit** como la función de distribución acumulada de la normal estándar utilizada en el **probit** son funciones sigmoides, lo que explica la similitud de los resultados obtenidos con ambas especificaciones (McCullagh and Nelder, 1989).

Un modelo sobreajustado puede presentar un rendimiento aparentemente elevado dentro de la muestra de estimación, pero mostrar una capacidad predictiva considerablemente inferior cuando se aplica a nuevos datos. En otras palabras, el modelo pierde capacidad de generalización. Este problema resulta especialmente relevante en el contexto del machine learning y el credit scoring, donde el objetivo principal es obtener modelos capaces de predecir correctamente el comportamiento de nuevos prestatarios (Hastie et al., 2009).

La selección adecuada de variables constituye una de las estrategias más utilizadas para mitigar este problema, ya que permite construir modelos más estables.

#### 4.2. Medidas de evaluación y selección de modelos

La selección del modelo óptimo requiere evaluar simultáneamente su capacidad predictiva y su grado de complejidad. En la literatura estadística y actuarial existen diferentes medidas para comparar modelos alternativos, las cuales pueden agruparse en dos grandes categorías: medidas no penalizadas y medidas penalizadas (Atance et al., 2020).

Las medidas no penalizadas evalúan exclusivamente el error de predicción o ajuste generado por el modelo, sin considerar el número de parámetros estimados. Entre las más utilizadas se encuentran el error cuadrático medio (Mean Squared Error, MSE), el error absoluto medio (Mean Absolute Error, MAE), el error porcentual absoluto medio (Mean Absolute Percentage Error, MAPE) y el coeficiente de determinación ( $R^2$ ). Estas métricas cuantifican en qué grado el modelo se ajusta a los datos, ya sea dentro o fuera de muestra, pero no incorporan ninguna valoración de la complejidad de la especificación. Por este motivo, cuando se calculan sobre la propia muestra de estimación no permiten discriminar entre modelos con distinto número de regresores, ya que la incorporación de variables adicionales no empeora el ajuste obtenido (Atance et al., 2020).

Por el contrario, las medidas penalizadas incorporan un término adicional que penaliza la incorporación excesiva del número de parámetros del modelo. Su objetivo es encontrar un equilibrio entre calidad de ajuste y parsimonia, evitando seleccionar modelos excesivamente parametrizados que puedan presentar problemas de sobreajuste (*overfitting*) (Hastie et al., 2009).

Dentro de este segundo grupo, los criterios de información Akaike Information Criterion (AIC) (Akaike, 1974) y Bayesian Information Criterion (BIC) (Schwarz, 1978) constituyen las herramientas más utilizadas para la comparación de modelos estadísticos y de *credit scoring*. Ambos criterios parten de la función de verosimilitud del modelo y añaden una penalización asociada al número de parámetros estimados. Estas dos medidas penalizadas pueden escribirse de la siguiente forma:

$$AIC = -2\log(L) + 2k \quad (11)$$

$$BIC = -2\log(L) + k\log(n) \quad (12)$$

donde  $L$  representa el valor de la función de verosimilitud evaluada en los parámetros estimados,  $k$  el número de parámetros del modelo y  $n$  el número de observaciones utilizadas en la estimación.

En ambos criterios, valores inferiores indican una mejor combinación entre capacidad explicativa y complejidad. No obstante, el criterio BIC aplica una penalización más severa

que el AIC cuando aumenta el número de parámetros, por lo que suele favorecer modelos más parsimoniosos. Por esta razón, ambos criterios se emplean conjuntamente para evaluar la robustez de los modelos candidatos y seleccionar la especificación final.

Conviene precisar que estos criterios pueden emplearse con dos finalidades distintas. La primera consiste en utilizarlos como regla de parada dentro del propio algoritmo de selección secuencial, incorporando o eliminando variables en función de la variación que producen en el AIC o el BIC. La segunda, adoptada en este trabajo, consiste en emplearlos como instrumento de comparación entre las especificaciones finales obtenidas mediante un criterio de selección alternativo, lo que permite valorar el equilibrio entre ajuste y parsimonia de los modelos resultantes.

### 4.3. Método Forward Stepwise

El método *Forward Stepwise* constituye una técnica secuencial de selección de variables ampliamente utilizada en la construcción de modelos predictivos. El procedimiento comienza con un modelo nulo y va incorporando iterativamente aquellas variables que generan la mayor mejora en el criterio de ajuste seleccionado, manteniéndose únicamente las que aportan capacidad explicativa adicional al modelo (Efroymson, 1960).

En cada iteración se evalúa la inclusión de cada una de las variables candidatas que aún no forman parte del modelo. La variable seleccionada es aquella cuya incorporación resulta más favorable según el criterio adoptado, que puede ser un criterio de información —como una reducción del AIC— o un criterio de significatividad estadística basado en el  $p$ -valor asociado al coeficiente. El proceso continúa hasta que la inclusión de nuevas variables deja de satisfacer dicho criterio. La Figura 1 representa esquemáticamente el funcionamiento del algoritmo bajo el criterio de significatividad empleado en este trabajo.




Figura 1: Esquema del procedimiento *forward stepwise*

Este procedimiento permite construir el modelo de forma progresiva, incorporando únicamente aquellas variables que contribuyen de manera significativa a mejorar su capacidad explicativa o predictiva (James et al., 2013).

#### 4.4. Método Backward Stepwise

El método *Backward Stepwise*, también conocido como eliminación hacia atrás (*backward elimination*), constituye una técnica secuencial de selección de variables ampliamente utilizada en la construcción de modelos estadísticos. Este procedimiento comienza con un modelo que incorpora todas las variables explicativas disponibles y elimina iterativamente aquellas que presentan una menor contribución al ajuste del modelo según un criterio previamente establecido (Efroymson, 1960).

A partir de este modelo inicial, el algoritmo evalúa la eliminación de cada una de las variables y descarta aquella que presenta una menor contribución según el criterio adoptado. Cuando dicho criterio se basa en la significatividad estadística, se elimina en cada paso la variable con mayor  $p$ -valor, siempre que este supere el umbral fijado. El proceso se repite de forma iterativa hasta que todas las variables retenidas satisfacen el criterio establecido. La Figura 2 representa esquemáticamente este procedimiento, cuya estructura es simétrica a la del algoritmo *forward* recogido en la Figura 1.



Figura 2: Esquema del procedimiento *backward stepwise*

Este método resulta especialmente útil cuando se dispone de un conjunto amplio de variables y se desea identificar cuáles de ellas aportan realmente información relevante para la predicción del fenómeno estudiado (Greene, 2012; James et al., 2013).

#### 4.5. Aplicación de los métodos stepwise en este trabajo

En este trabajo se utilizan los métodos Forward Stepwise y Backward Stepwise para seleccionar el conjunto de variables más adecuado en la estimación de los modelos *logit* y *probit* utilizados para el análisis del riesgo crediticio.

El criterio de selección adoptado es la significatividad estadística individual de los coeficientes, fijando un nivel del 5 % ( $\alpha = 0.05$ ). En el procedimiento *forward*, partiendo de un modelo que contiene únicamente la constante, se incorpora en cada iteración la variable cuyo p-valor resulta menor, siempre que sea inferior a 0.05; el algoritmo se detiene cuando ninguna variable candidata satisface dicha condición. En el procedimiento *backward*, partiendo del modelo completo, se elimina en cada iteración la variable con mayor p-valor mientras este supere 0.05. Este criterio se ha preferido a las reglas basadas en criterios de información por su transparencia interpretativa y por su correspondencia directa con el contraste de significatividad habitual en el análisis econométrico aplicado.

La aplicación de estos métodos resulta especialmente útil en el contexto del presente estudio, ya que permite construir modelos de *credit scoring* más estables y evitar la inclusión de variables irrelevantes que podrían deteriorar la capacidad predictiva del modelo.

## 5. Datos desbalanceados y técnica SMOTE

Una dificultad recurrente al modelizar el riesgo de crédito es que las dos categorías de la variable dependiente no aparecen representadas en proporciones comparables. Se habla de datos desbalanceados cuando una de ellas reúne un volumen de observaciones muy superior al de la otra, situación que en las carteras de préstamos se traduce en una mayoría de operaciones atendidas con normalidad frente a un grupo reducido de impagos (He and Garcia, 2009).

Este desequilibrio en la distribución de las clases puede afectar negativamente al rendimiento de los modelos de clasificación. En particular, los algoritmos de aprendizaje tienden a favorecer la clase mayoritaria durante el proceso de estimación, lo que puede provocar una capacidad limitada para identificar correctamente los casos pertenecientes a

la clase minoritaria, que en este caso corresponden a los prestatarios con mayor riesgo de impago (Dastile et al., 2020).

### 5.1. Datos desbalanceados en credit scoring

En una cartera crediticia ordinaria, los prestatarios que dejan de atender sus pagos constituyen una minoría frente al conjunto de clientes. Las bases de datos con las que se construyen los modelos de scoring heredan por tanto ese reparto desigual entre categorías.

Este problema resulta especialmente relevante porque los casos de impago, a pesar de ser menos frecuentes, son precisamente los que presentan mayor interés para las instituciones financieras. Una incorrecta identificación de estos casos puede traducirse en pérdidas económicas importantes para las entidades de crédito y financieras.

Desde el punto de vista estadístico, el desbalanceo de datos puede provocar que los modelos se ajusten principalmente a la clase mayoritaria, generando predicciones aparentemente correctas en términos de precisión global, pero con una capacidad limitada para detectar correctamente los eventos de impago. Este fenómeno puede dar lugar a modelos que clasifican correctamente la mayoría de prestatarios solventes, pero que fallan en identificar a aquellos con mayor probabilidad de incumplimiento (He and Garcia, 2009).

No se trata de una cuestión menor dentro de la literatura: el reparto desigual de las clases figura de forma recurrente entre las dificultades señaladas al trasladar métodos de aprendizaje automático al terreno crediticio, y existen trabajos que han medido su efecto sobre distintos clasificadores y ensayado vías para corregirlo (Brown and Mues, 2012).

### 5.2. Técnicas para tratar datos desbalanceados

Las respuestas propuestas ante un reparto desigual de las clases admiten una clasificación en tres bloques:

- Métodos de muestreo, que intervienen sobre el reparto de las clases antes de estimar, alterando únicamente la muestra de entrenamiento.
- Métodos basados en el algoritmo, que modifican el proceso de aprendizaje para penalizar de forma diferente los errores cometidos en cada clase.
- Métodos híbridos, que combinan ambas estrategias.

Dentro de los métodos basados en el muestreo, una de las técnicas más utilizadas consiste en el sobremuestreo de la clase minoritaria, que busca incrementar artificialmente el número de observaciones pertenecientes a dicha clase. De esta forma se pretende equilibrar la distribución de las clases y facilitar que el modelo aprenda patrones asociados a los casos menos frecuentes.

Ahora bien, replicar sin más las observaciones escasas expone al modelo a un riesgo evidente de sobreajuste, ya que los mismos registros aparecen repetidos varias veces. De ahí que se hayan propuesto procedimientos que, en lugar de copiar, construyen observaciones nuevas a partir de las disponibles. El más extendido es la Synthetic Minority Over-sampling Technique (SMOTE) (Chawla et al., 2002).

### 5.3. Synthetic Minority Over-sampling Technique (SMOTE)

Propuesta por Chawla et al. (2002), SMOTE se ha convertido en la referencia habitual cuando las clases están mal repartidas. Su particularidad frente al sobremuestreo convencional está en el origen de las nuevas observaciones: no son copias de registros ya presentes, sino puntos contruidos artificialmente dentro de la región que ocupa la categoría escasa.

El funcionamiento del algoritmo se basa en la generación de observaciones sintéticas mediante interpolación entre instancias cercanas de la clase minoritaria. La Figura 3 ilustra gráficamente este procedimiento sobre un conjunto de datos bidimensional simulado. En concreto, para cada observación perteneciente a la clase minoritaria, el algoritmo identifica un conjunto de vecinos más cercanos dentro de la misma clase. Posteriormente, se generan nuevos puntos sintéticos situados en el espacio de características entre la observación original y algunos de sus vecinos.




Figura 3: Funcionamiento del algoritmo SMOTE mediante interpolación entre observaciones de la clase minoritaria.

Nota. Elaboración propia a partir de Chawla et al. (2002).

El resultado es un conjunto de entrenamiento en el que la categoría escasa gana peso sin que ello se reduzca a repetir registros idénticos, lo que sitúa al modelo en mejores condiciones para reconocer los perfiles poco frecuentes.

### 5.4. Ventajas y limitaciones del método

Frente a otras alternativas de remuestreo, SMOTE ofrece dos ventajas claras. La primera es que otorga a la categoría escasa un peso suficiente dentro de la muestra de entrenamiento, de modo que el algoritmo dispone de material bastante para reconocer sus regularidades. La segunda es que, al fabricar puntos nuevos en vez de repetir los que ya existen, atenúa el sobreajuste que acompaña habitualmente al sobremuestreo por duplicación (Chawla et al., 2002).

La evidencia empírica disponible en el ámbito crediticio apunta en esa dirección: rebalancear la muestra suele traducirse en clasificadores que localizan una fracción mayor

de los incumplimientos, que es justamente donde fallan los modelos entrenados sobre distribuciones desiguales (Brown and Mues, 2012).

No obstante, el uso de SMOTE también presenta algunas limitaciones. En particular, la generación de observaciones sintéticas puede introducir ruido en el conjunto de datos si las instancias utilizadas para la interpolación no representan adecuadamente la estructura real de los datos. Además, en presencia de variables altamente correlacionadas o distribuciones complejas, la generación de ejemplos sintéticos puede alterar la distribución original de los datos (Han et al., 2005).

Por esta razón, la aplicación de técnicas de sobremuestreo debe realizarse con cautela y evaluarse cuidadosamente mediante medidas de rendimiento predictivo, tanto dentro de muestra como fuera de muestra.

En este trabajo, la técnica SMOTE se utiliza como herramienta para tratar el desbalanceo presente en los datos de riesgo crediticio utilizados en la aplicación empírica. En particular, se genera un conjunto de entrenamiento balanceado mediante la creación de observaciones sintéticas de la clase minoritaria, con el objetivo de mejorar la capacidad de los modelos para identificar correctamente los casos de impago.

## 6. Modelos de aprendizaje automático: Random Forest

Además de los GLM y de las técnicas de tratamiento del desbalance descritas en los apartados anteriores, este trabajo incorpora un algoritmo de aprendizaje automático como término de comparación. La finalidad no es sustituir el enfoque econométrico, sino disponer de una referencia que permita valorar si una especificación más flexible aporta mejoras predictivas relevantes frente a los modelos `logit` y `probit`, y a qué coste en términos de interpretabilidad.

### 6.1. Árboles de decisión y métodos de ensamble

El punto de partida del algoritmo es el árbol de decisión. Un árbol de clasificación divide de forma recursiva el espacio de las variables explicativas en regiones disjuntas mediante particiones binarias sucesivas, seleccionando en cada nodo la variable y el punto de corte que generan los grupos más homogéneos respecto a la variable objetivo (Breiman et al., 1984). La homogeneidad suele medirse mediante el índice de Gini:

$$G = \sum_{c=1}^C \hat{p}_c(1 - \hat{p}_c), \quad (13)$$

donde  $\hat{p}_c$  representa la proporción de observaciones de la clase  $c$  dentro del nodo considerado y  $C$  el número total de clases, que en este caso es igual a dos. Valores próximos a cero indican nodos prácticamente puros, es decir, formados casi exclusivamente por observaciones de una misma clase.

Los árboles individuales presentan una ventaja evidente en términos de interpretación, ya que la secuencia de particiones puede representarse gráficamente y traducirse en reglas de decisión sencillas. Sin embargo, adolecen de una elevada varianza: pequeñas modificaciones en la muestra de entrenamiento pueden alterar sustancialmente la estructura del árbol y, con ella, sus predicciones (Hastie et al., 2009).

Los métodos de ensamble surgen precisamente para mitigar este problema combinando múltiples modelos base. El procedimiento de *bagging* (*bootstrap aggregating*) consiste en extraer  $B$  muestras aleatorias con reemplazamiento de la muestra de entrenamiento, estimar un árbol sobre cada una de ellas y promediar posteriormente sus predicciones. Dado que los árboles individuales no están sesgados pero sí presentan varianza elevada, su agregación reduce esta última sin incrementar el sesgo (James et al., 2021).

## 6.2. El algoritmo Random Forest

El algoritmo Random Forest, propuesto por Breiman (2001), introduce una modificación adicional sobre el *bagging*. En cada partición de cada árbol, en lugar de evaluar la totalidad de las variables explicativas disponibles, el algoritmo considera únicamente un subconjunto aleatorio de ellas. Esta restricción impide que las variables con mayor capacidad predictiva dominen la primera partición de todos los árboles y, en consecuencia, reduce la correlación entre los árboles del ensamble. Puesto que la varianza de una media disminuye más rápidamente cuanto menos correlacionados están sus componentes, esta decorrelación mejora la estabilidad del modelo agregado. La Figura 4 representa esquemáticamente el funcionamiento del algoritmo.




Figura 4: Esquema de funcionamiento del algoritmo Random Forest

La probabilidad estimada para una observación  $x$  se obtiene como el promedio de las probabilidades predichas por los  $B$  árboles que componen el bosque:

$$\hat{p}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(x), \quad (14)$$

lo que permite emplear el algoritmo como estimador de la probabilidad de impago y aplicar sobre dicha estimación el mismo umbral de clasificación utilizado en los modelos GLM.

Random Forest proporciona además una medida de importancia relativa de las variables, calculada habitualmente como la reducción media del índice de Gini atribuible a cada variable a lo largo de todos los árboles del ensamble. La Figura 5 ilustra de forma esquemática este procedimiento. Esta medida permite ordenar los predictores según su contribución al modelo, si bien no informa sobre el signo ni sobre la magnitud del efecto, a diferencia de los coeficientes estimados en un GLM, y tiende a favorecer a las variables continuas y a aquellas con un mayor número de valores distintos (Hastie et al., 2009). Por estas limitaciones, y dado que en este trabajo Random Forest se emplea como término de comparación predictiva frente a las especificaciones GLM y no como instrumento de interpretación de los determinantes del impago, el análisis empírico no recurre a esta medida: la interpretación económica de los efectos se apoya en los coeficientes y en los *odds ratios* presentados en el apartado 8.1.




Figura 5: Esquema del procedimiento de cálculo de la importancia relativa de las variables en Random Forest

Nota. Elaboración propia. Esquema ilustrativo del procedimiento; las variables  $X_j$  representadas en el último panel son genéricas y no corresponden a las empleadas en la aplicación empírica.

### 6.3. Ventajas y limitaciones en el contexto del credit scoring

La principal ventaja del algoritmo reside en su capacidad para capturar relaciones no lineales e interacciones entre variables sin necesidad de especificarlas previamente, lo que resulta especialmente útil en bases de datos financieras con estructuras heterogéneas. A ello se añade su robustez frente a valores extremos y la ausencia de requisitos sobre la escala de las variables explicativas. Diversos trabajos han documentado su buen desempeño en problemas de riesgo crediticio (Brown and Mues, 2012; Dastile et al., 2020).

Frente a estas ventajas, el algoritmo presenta una limitación relevante en el ámbito financiero: su carácter de modelo de caja negra. Un ensamble de varios cientos de árboles no admite una representación compacta ni permite justificar de forma directa por qué una solicitud concreta ha sido clasificada de una determinada manera. Esta característica resulta problemática en un entorno regulado, en el que las entidades deben ser capaces de documentar, validar y explicar las decisiones adoptadas a partir de sus modelos (Bücker et al., 2022). Por este motivo, la comparación desarrollada en este trabajo no se limita a la capacidad predictiva, sino que incorpora también la dimensión de interpretabilidad.

#### 6.4. Combinación con técnicas de tratamiento del desbalance

El algoritmo Random Forest no resuelve por sí mismo el problema del desbalance de clases descrito en la sección 5. Al construirse cada árbol sobre una muestra que reproduce la distribución original, las particiones tienden a favorecer a la clase mayoritaria, de modo que el modelo puede alcanzar un elevado acierto global manteniendo una capacidad limitada de detección de los casos de impago (He and Garcia, 2009).

La literatura contempla dos estrategias para corregir este comportamiento, que operan sobre elementos distintos del procedimiento (Chawla et al., 2002). La primera consiste en ponderar las clases de forma inversamente proporcional a su frecuencia, penalizando en mayor medida los errores cometidos sobre la clase minoritaria durante la construcción de cada árbol; se trata, por tanto, de una intervención sobre el criterio de ajuste del algoritmo. La segunda consiste en aplicar previamente una técnica de remuestreo como SMOTE, generando observaciones sintéticas de la clase minoritaria hasta equilibrar la distribución de entrenamiento; en este caso la intervención se produce sobre los datos y no sobre el algoritmo.

Ambas estrategias persiguen el mismo objetivo pero no son equivalentes ni conducen necesariamente a los mismos resultados. En la aplicación empírica se estiman las dos variantes, lo que permite contrastar el efecto de cada una de ellas sobre el equilibrio entre acierto global y detección de impagos.

## 7. Aplicación práctica

Con el objetivo de evaluar empíricamente los modelos descritos en las secciones anteriores, en este trabajo se desarrolla una aplicación práctica basada en un conjunto de datos de préstamos. A partir de estos datos se estiman diferentes modelos de credit scoring, utilizando especificaciones **logit** y **probit** dentro del marco de los GLM, así como técnicas de selección de variables y métodos de balanceo de datos.

El análisis empírico se centra en comparar el rendimiento predictivo de distintos modelos, evaluando su capacidad para identificar correctamente los casos de impago. Para ello se analizan los resultados obtenidos tanto dentro de muestra como fuera de muestra, lo que permite evaluar la capacidad de generalización de los modelos.

Con el fin de facilitar la reproducibilidad del análisis, el código, los notebooks y los materiales complementarios utilizados en este trabajo se encuentran disponibles en el siguiente repositorio de GitHub: <https://github.com/marcbagur20/TFG-credit-scoring>. (Bagur, 2026)

### 7.1. Datos y tratamiento de la información

El análisis empírico de este trabajo se basa en el conjunto de datos Okam (2024), disponible públicamente en la plataforma Kaggle, Inc. (2024). Esta base de datos recoge información sobre préstamos concedidos a particulares a través de la plataforma Prosper, incorporando variables relativas a las características financieras de los prestatarios, su historial crediticio, las condiciones del préstamo y el estado final de la operación.

Las bases de datos utilizadas en problemas de *credit scoring* suelen requerir un proceso exhaustivo de preparación y transformación antes de poder ser utilizadas en la estimación de modelos predictivos. La calidad del modelo depende en gran medida de la calidad del tratamiento previo de los datos, por lo que esta etapa constituye una fase fundamental en el proceso de modelización (Svolba, 2006).

En este trabajo, el preprocesamiento de los datos se realizó utilizando Python, principalmente mediante las librerías **NumPy** (NumPy Developers, 2024), **Pandas** (pandas Development Team, 2024), **Scikit-learn** (scikit-learn Developers, 2024), **Statsmodels** (statsmodels Developers, 2024) y **Matplotlib** (Matplotlib Development Team, 2024).

La base de datos original cuenta con 113.937 observaciones y 81 variables. Estas variables incluyen información sobre el importe del préstamo, el tipo de interés aplicado, la duración de la operación, la situación laboral del prestatario, su renta declarada, su ratio de endeudamiento, su historial crediticio y el estado final del préstamo. No obstante, no todas las variables disponibles resultan adecuadas para la estimación del modelo, ya sea por presentar valores perdidos, contener información redundante, no estar disponible en el momento de concesión del préstamo o no aportar una interpretación económica clara dentro del análisis de riesgo crediticio.

Desde el punto de vista de la delimitación del análisis, conviene precisar el ámbito espacial y temporal de la información utilizada. Prosper es una plataforma estadounidense de préstamos entre particulares (*marketplace lending* o *peer-to-peer lending*), de modo que las operaciones analizadas corresponden a crédito al consumo no garantizado concedido a prestatarios residentes en Estados Unidos. La base de datos abarca las operaciones originadas entre 2005 y comienzos de 2014, un período que incluye la crisis financiera de

2008 y la posterior fase de recuperación. Debe señalarse además que, en octubre de 2008, la plataforma suspendió la emisión de nuevas operaciones y reestructuró su modelo tras las conversaciones mantenidas con la Securities and Exchange Commission, no reanudando su actividad hasta julio de 2009. Como parte de dicha reestructuración, el sistema interno de calificación fue sustituido por uno nuevo, lo que explica que determinadas variables de valoración del riesgo solo estén disponibles para las operaciones posteriores a esa fecha (Prosper Marketplace, Inc., 2012).

Esta delimitación resulta relevante por dos motivos. En primer lugar, porque el modelo de negocio de una plataforma de financiación entre particulares difiere del de una entidad bancaria tradicional, tanto en el perfil de los solicitantes como en los criterios de concesión, lo que condiciona la validez externa de los resultados. En segundo lugar, porque la heterogeneidad macroeconómica del período analizado implica que las cohortes de préstamos no son homogéneas entre sí, aspecto que se retoma en el apartado 7.1.1 al discutir la construcción de la variable dependiente.

A modo de resumen, la Tabla 1 recoge algunas de las variables más relevantes utilizadas en la construcción de los modelos. La descripción detallada del conjunto completo de variables puede consultarse en la documentación original del conjunto de datos (Okam, 2024).

Tabla 1: Resumen de algunas variables relevantes utilizadas en el análisis

| Variable                       | Descripción                                                                                                      |
|--------------------------------|------------------------------------------------------------------------------------------------------------------|
| <i>LoanStatus</i>              | Estado final del préstamo. Se utiliza como base para construir la variable dependiente de impago.                |
| <i>BorrowerRate</i>            | Tipo de interés aplicado al prestatario en la operación de préstamo.                                             |
| <i>BorrowerAPR</i>             | Coste anual efectivo del préstamo para el prestatario, incluyendo intereses y otros costes asociados.            |
| <i>LoanOriginalAmount</i>      | Importe original concedido en el préstamo.                                                                       |
| <i>Term</i>                    | Duración del préstamo, expresada en meses.                                                                       |
| <i>DebtToIncomeRatio</i>       | Ratio entre la deuda del prestatario y sus ingresos, utilizado como indicador de capacidad de pago.              |
| <i>StatedMonthlyIncome</i>     | Ingresos mensuales declarados por el prestatario.                                                                |
| <i>EmploymentStatus</i>        | Situación laboral del prestatario en el momento de solicitud del préstamo.                                       |
| <i>CreditScoreRangeLower</i>   | Límite inferior del rango de puntuación crediticia del prestatario, utilizado como medida de calidad crediticia. |
| <i>DelinquenciesLast7Years</i> | Número de incidencias o retrasos en pagos registrados durante los últimos siete años.                            |
| <i>InquiriesLast6Months</i>    | Número de consultas crediticias realizadas sobre el prestatario en los últimos seis meses.                       |
| <i>OpenCreditLines</i>         | Número de líneas de crédito abiertas del prestatario.                                                            |

Tras el proceso completo de limpieza y transformación, la base de datos final queda compuesta por 112.498 observaciones y 42 variables explicativas, tal y como se muestra en la Tabla 2. La reducción desde las 81 variables originales hasta las 42 variables finales

responde a criterios de calidad de la información, disponibilidad de datos, eliminación de variables redundantes y adecuación económica al problema de predicción del impago.

Tabla 2: Dimensiones del conjunto de datos tras el proceso de limpieza y transformación

| Elemento                                 | Valor   |
|------------------------------------------|---------|
| Número de observaciones finales          | 112.498 |
| Número de variables originales           | 81      |
| Número de variables explicativas finales | 42      |

En las siguientes secciones se explican las principales decisiones adoptadas durante el proceso de tratamiento de la información, incluyendo la construcción de la variable dependiente, la depuración de observaciones, el tratamiento de valores perdidos, la transformación de variables categóricas y la selección de variables explicativas. Estas decisiones no responden únicamente a criterios técnicos de disponibilidad, sino también a la relevancia económica de las variables dentro de la literatura de *credit scoring*.

En particular, las variables asociadas a la puntuación crediticia del prestatario constituyen una medida directa de su calidad crediticia, mientras que indicadores como el *DebtToIncomeRatio* reflejan su capacidad de pago. Asimismo, variables relacionadas con el coste del préstamo, como el tipo de interés o la tasa anual equivalente del prestatario, capturan el riesgo percibido por la entidad financiera en el momento de la concesión del crédito. En conjunto, estas variables permiten aproximar tanto el perfil de riesgo como la situación financiera del prestatario (Thomas, 2009).

#### 7.1.1. Construcción de la variable dependiente (Default)

Uno de los pasos más importantes del proceso de modelización consiste en definir correctamente la variable objetivo, que en este caso corresponde a la ocurrencia de impago del préstamo.

En el dataset original, la variable **LoanStatus** contiene múltiples estados posibles del préstamo. Para construir la variable binaria de default, se definieron tres posibles escenarios de clasificación:

- Escenario A (mínimo). Default únicamente si el estado del préstamo es *Chargedoff* o *Defaulted*.
- Escenario B (estándar). Default si el préstamo está en estado *Chargedoff*, *Defaulted* o presenta mora superior a 60 días.
- Escenario C (amplio). Incluye también situaciones de mora entre 31 y 60 días.

La Tabla 3 contiene una descripción de los diferentes estados de la variable *Default* que va a ser utilizada como variable dependiente. Dicha tabla contiene la información del número de los diferentes escenarios que aparecen recogidos en la base de datos, así como el porcentaje de individuos que se les rechaza el crédito en cada categoría.

Tras comparar la tasa de impago obtenida en cada escenario, se seleccionó el escenario B, ya que refleja de forma más adecuada el concepto de impago utilizado habitualmente en la gestión del riesgo crediticio, donde el default suele definirse en función de estados de mora significativos o incumplimiento efectivo del préstamo (Abdou and Pointon, 2011). Bajo esta definición, la muestra final quedó constituida por 112.498 observaciones, registrándose

Tabla 3: Escenarios considerados para la construcción de la variable **default**.

| Escenario  | Descripción                                                       | Muestras | Tasa default (%) |
|------------|-------------------------------------------------------------------|----------|------------------|
| A_minimo   | Default solo si <b>Chargedoff</b> o <b>Defaulted</b> .            | 111865   | 15.21            |
| B_estandar | Default si <b>Chargedoff</b> / <b>Defaulted</b> o mora > 60 días. | 112498   | 15.68            |
| C_amplio   | Default incluye mora > 30 días.                                   | 112861   | 15.95            |

una tasa de default del 15.68 %, valores que se consideran representativos para el posterior desarrollo y validación del modelo.

La variable **Default** se define entonces como:

$$default_i = \begin{cases} 1 & \text{si el préstamo } i \text{ cumple las condiciones del escenario B,} \\ 0 & \text{en caso contrario,} \end{cases} \quad (15)$$

donde el escenario B considera en situación de impago aquellas operaciones cuyo estado final es *Chargedoff* o *Defaulted*, así como aquellas que presentan una mora superior a 60 días, según la clasificación recogida en la Tabla 3.

La construcción de la variable dependiente a partir del estado del préstamo en el momento de recogida de los datos presenta una limitación que conviene explicitar. Una proporción sustancial de las operaciones clasificadas como no impago corresponde a préstamos que continuaban vigentes (*Current*) en dicho momento y que, por tanto, no habían alcanzado su vencimiento: concretamente, el 59.6 % de las observaciones de la clase mayoritaria. Estos contratos podrían incurrir en impago con posterioridad, de modo que la variable objetivo incorpora un fenómeno de censura por la derecha.

La Tabla 4 evidencia este efecto al desagregar la muestra por año de originación. La tasa de impago observada desciende desde el 39.48 % en la cohorte de 2007, plenamente vencida, hasta el 1.70 % en la de 2013 y el 0.00 % en la de 2014, cohortes en las que el 91.2 % y el 99.3 % de las operaciones seguían vigentes, respectivamente. El patrón no responde, por tanto, a una mejora real de la calidad crediticia, sino a que las operaciones más recientes han dispuesto de menos tiempo para incurrir en impago.

Tabla 4: Tasa de impago y proporción de préstamos vigentes por año de originación

| Año  | Observaciones | Tasa de impago (%) | Préstamos vigentes (%) |
|------|---------------|--------------------|------------------------|
| 2005 | 22            | 0.00               | 0.0                    |
| 2006 | 5 902         | 39.39              | 0.0                    |
| 2007 | 11 460        | 39.48              | 0.0                    |
| 2008 | 11 551        | 32.97              | 0.0                    |
| 2009 | 2 047         | 15.19              | 0.0                    |
| 2010 | 5 649         | 16.68              | 0.3                    |
| 2011 | 11 019        | 20.25              | 29.6                   |
| 2012 | 18 987        | 15.42              | 55.2                   |
| 2013 | 33 708        | 1.70               | 91.2                   |
| 2014 | 12 153        | 0.00               | 99.3                   |

*Nota.* Elaboración propia a partir de Okam (2024). La columna de préstamos vigentes recoge el porcentaje de operaciones cuyo estado en el momento de recogida de los datos era *Current*. El año 2005 incluye únicamente 22 operaciones, por lo que su tasa no resulta representativa.

La principal implicación para el análisis es que parte de la variabilidad explicada por el modelo puede estar asociada a la antigüedad de la operación y no exclusivamente al perfil de riesgo del prestatario. La literatura sobre riesgo de crédito ha abordado esta cuestión mediante técnicas de análisis de supervivencia, que modelizan el tiempo transcurrido hasta el impago en lugar de su ocurrencia dentro de un horizonte fijo y permiten tratar de forma explícita las observaciones censuradas (Banasik et al., 1999). Una alternativa más sencilla consistiría en restringir el análisis a las cohortes plenamente vencidas. Ambas opciones exceden el alcance de este trabajo y se recogen entre sus limitaciones y líneas futuras.

### 7.1.2. Limpieza inicial del dataset

Una vez definida la variable objetivo, se realiza un proceso de limpieza básica del dataset. El proceso incluye las siguientes etapas:

1. **Eliminación de duplicados.** Se eliminan las observaciones duplicadas del conjunto de datos para evitar que ciertas instancias influyan de forma desproporcionada en el entrenamiento del modelo.
2. **Conversión de valores infinitos.** Los valores infinitos pueden aparecer como resultado de operaciones matemáticas. Estos valores se reemplazan por valores faltantes (NaN) para su posterior tratamiento.
3. **Identificación de valores faltantes.** Se calcula el porcentaje de valores faltantes por variable con el objetivo de identificar aquellas variables con una proporción elevada de datos ausentes.

Se ha decidido eliminar aquellas variables que presentan más del 40 % de valores faltantes, ya que su inclusión podría introducir sesgos en el modelo. La Tabla 5 muestra las variables con mayor porcentaje de valores faltantes en el dataset. Se observa que varias variables presentan más del 80 % de datos ausentes. Siguiendo la regla establecida en el proceso de limpieza, se eliminaron aquellas variables con más del 40 % de valores faltantes, ya que su inclusión podría introducir ruido y sesgos en el modelo. Tras aplicar el proceso de limpieza descrito anteriormente, el dataset contiene 112498 observaciones y 70 variables.

Tabla 5: Variables con mayor porcentaje de valores faltantes

| Variable                            | % NA  |
|-------------------------------------|-------|
| GroupKey                            | 88.17 |
| LoanFirstDefaultedCycleNumber       | 84.93 |
| ScorexChangeAtTimeOfListing         | 83.52 |
| ProsperPrincipalBorrowed            | 80.73 |
| TotalProsperLoans                   | 80.73 |
| TotalProsperPaymentsBilled          | 80.73 |
| OnTimeProsperPayments               | 80.73 |
| ProsperPaymentsOneMonthPlusLate     | 80.73 |
| ProsperPrincipalOutstanding         | 80.73 |
| ProsperPaymentsLessThanOneMonthLate | 80.73 |

El tratamiento de los valores faltantes, que aparece recogido en la Tabla 6, se realizó atendiendo a la naturaleza de cada variable y al significado económico de la ausencia de información.

Las dos primeras reglas se aplican a variables concretas cuya ausencia admite una lectura directa. En **Recommendations**, que recoge el número de recomendaciones recibidas por el prestatario dentro de la plataforma, la falta de valor equivale a la ausencia de recomendaciones, por lo que se asigna el valor cero. En **Investors**, que recoge el número de inversores que financiaron la operación, se asigna el valor uno, ya que todo préstamo efectivamente concedido cuenta necesariamente con al menos un inversor y la unidad constituye por tanto el valor mínimo admisible. Debe precisarse que ambas reglas tienen carácter preventivo: en la muestra empleada ninguna de las dos variables presenta valores faltantes.

La tercera regla se aplica al resto de variables cuantitativas y es la que resulta efectiva en la práctica. En la mayoría de los casos se trata de variables de recuento —incidencias de pago, consultas crediticias o registros públicos— en las que la ausencia de valor indica que el prestatario no registra ese tipo de eventos, de modo que el cero constituye la codificación económicamente correcta. En otras variables, sin embargo, esta interpretación resulta menos inmediata: es el caso de **DebtToIncomeRatio**, con un 7.51 % de valores ausentes, o de **EmploymentStatusDuration**, con un 6.69 %, en las que el cero se corresponde con un valor observable y no distingue por completo la ausencia de información de un valor nulo real. La adopción de una regla homogénea permite conservar la totalidad de las observaciones y evita imputaciones más elaboradas que introducirían supuestos adicionales sobre el mecanismo de generación de los datos, si bien esta limitación se recoge expresamente en el apartado ??.

La eliminación sistemática de todas las observaciones con valores faltantes habría supuesto, por el contrario, una pérdida significativa de información, reduciendo el tamaño efectivo de la muestra y pudiendo introducir sesgos de selección en el análisis.

Además, la eliminación sistemática de todas las observaciones con valores faltantes habría supuesto una pérdida significativa de información, reduciendo el tamaño efectivo de la muestra y pudiendo introducir sesgos de selección en el análisis.

Tabla 6: Tratamiento de valores faltantes

| Variable                     | Tratamiento        | Justificación                                                                                                                       |
|------------------------------|--------------------|-------------------------------------------------------------------------------------------------------------------------------------|
| Recommendations              | NA $\rightarrow$ 0 | La ausencia de valor se interpreta como ausencia de recomendaciones recibidas por el prestatario dentro de la plataforma.           |
| Investors                    | NA $\rightarrow$ 1 | Toda operación efectivamente financiada cuenta con al menos un inversor, por lo que la unidad constituye el valor mínimo admisible. |
| Resto de variables numéricas | NA $\rightarrow$ 0 | Regla general aplicada al conjunto de variables cuantitativas, detallada en el texto.                                               |

*Nota.* Las dos primeras reglas tienen carácter preventivo: en la muestra utilizada ninguna de estas dos variables presenta valores faltantes.

### 7.1.3. Eliminación de variables no relevantes

Posteriormente, se eliminaron diversas variables que no resultaban adecuadas para la estimación de los modelos. Esta decisión responde a tres criterios principales: evitar variables sin contenido predictivo real, prevenir problemas de fuga de información y excluir variables que incorporan valoraciones internas de la propia plataforma. En modelos predictivos, una correcta selección de variables es fundamental para evitar resultados artificialmente optimistas y garantizar que el modelo pueda ser aplicado de forma coherente en un contexto real de decisión crediticia (Svolba, 2006; Kuhn and Johnson, 2013).

#### 1. Identificadores.

Se eliminaron variables cuya función principal era identificar de forma única un préstamo, una solicitud o un prestatario, pero que no contenían información económica interpretable ni capacidad predictiva generalizable. Este tipo de variables pueden servir para la gestión interna de la base de datos, pero no aportan información relevante sobre la solvencia del prestatario o la probabilidad de impago. Además, su inclusión podría inducir al modelo a aprender patrones específicos de la muestra, sin utilidad fuera del conjunto de datos analizado.

En esta categoría se eliminaron variables como `ListingKey`, `LoanKey` y `MemberKey`. La variable `ListingKey` identifica de forma única la solicitud o anuncio del préstamo; `LoanKey` identifica de forma única el préstamo concedido; y `MemberKey` identifica al prestatario dentro de la plataforma. Por tanto, se consideran identificadores técnicos y no variables explicativas del riesgo crediticio.

#### 2. Variables con fuga de información (*data leakage*).

También se eliminaron variables que podían generar problemas de fuga de información. La fuga de información se produce cuando el modelo utiliza, durante el proceso de entrenamiento, información que no estaría disponible en el momento real en que debería realizarse la predicción (Kaufman et al., 2012). En estos casos, el rendimiento estimado del modelo puede resultar artificialmente elevado, ya que el algoritmo estaría utilizando información posterior o indirectamente relacionada con

el resultado que se pretende predecir.

En el contexto de este trabajo, el objetivo es estimar la probabilidad de impago a partir de información disponible en el momento de concesión o evaluación inicial del préstamo. Por ello, se excluyeron variables que reflejan la evolución posterior del préstamo o pérdidas observadas una vez iniciado el contrato. Entre ellas se encuentran `LoanCurrentDaysDelinquent` y `LP_NetPrincipalLoss`.

La variable `LoanCurrentDaysDelinquent` recoge los días actuales de mora del préstamo, por lo que contiene información directamente relacionada con el incumplimiento una vez que el préstamo ya está vivo. Por su parte, `LP_NetPrincipalLoss` recoge la pérdida neta de principal asociada al préstamo, información que solo puede conocerse después de observar su evolución. Incluir estas variables en el modelo supondría utilizar información posterior al momento de decisión, generando un sesgo en la evaluación del rendimiento predictivo.

### 3. Ratings internos de la plataforma.

Finalmente, se eliminaron variables que incorporan evaluaciones internas de riesgo generadas por la propia plataforma Prosper. Estas variables no son observaciones puramente originales del prestatario, sino resultados de sistemas internos de calificación o estimación. Su inclusión podría introducir redundancia en el modelo, ya que en parte condensan información previamente procesada por la entidad.

En esta categoría se encuentran variables como `ProsperRating` y `EstimatedReturn`. La variable `ProsperRating` representa una calificación interna asignada por la plataforma al préstamo, mientras que `EstimatedReturn` recoge una estimación del rendimiento esperado de la operación. Aunque estas variables pueden tener relación con el riesgo del préstamo, se excluyen para evitar que el modelo dependa de valoraciones ya elaboradas por Prosper y para construir una estimación basada en variables observables y económicamente interpretables.

En conjunto, la eliminación de estas variables permite construir una base de datos más adecuada para el objetivo del trabajo. El modelo resultante se estima únicamente con información que puede interpretarse económicamente y que, en principio, estaría disponible en el momento de evaluar el riesgo crediticio del prestatario. De este modo, se reduce el riesgo de sobreestimar la capacidad predictiva del modelo y se mejora la coherencia metodológica del análisis empírico.

#### 7.1.4. Transformación de variables explicativas

Una vez eliminadas las variables no relevantes, se procedió a transformar determinadas variables originales con el objetivo de adaptarlas a la estimación de los modelos `logit` y `probit`. Este proceso permitió convertir variables categóricas en variables numéricas, resumir información contenida en rangos y construir indicadores binarios interpretables desde el punto de vista económico. Las principales transformaciones realizadas fueron las siguientes:

##### 1. Construcción de la variable `FICOScore`.

La base de datos original no proporciona directamente una única puntuación FICO, sino dos variables que recogen el límite inferior y superior del rango de puntuación crediticia del prestatario: `CreditScoreRangeLower` y `CreditScoreRangeUpper`.

La variable `CreditScoreRangeLower` representa el límite inferior del rango de puntuación crediticia asignado al prestatario, mientras que `CreditScoreRangeUpper` representa el límite superior de dicho rango. Para obtener una medida única de calidad crediticia, se construyó la variable `FICOScore` como la media aritmética entre ambos límites:

$$\text{FICOScore}_i = \frac{\text{CreditScoreRangeLower}_i + \text{CreditScoreRangeUpper}_i}{2} \quad (16)$$

Esta transformación permite aproximar la puntuación crediticia media del prestatario y utilizarla como una variable explicativa continua dentro del modelo. Desde el punto de vista económico, una mayor puntuación FICO suele asociarse con una mejor calidad crediticia y, por tanto, con una menor probabilidad esperada de impago.

No obstante, debe señalarse que esta variable no forma parte de la especificación final de los modelos. Al construirse como media aritmética de `CreditScoreRangeLower` y `CreditScoreRangeUpper`. De hecho, su correlación con ambas resulta prácticamente perfecta (superior a 99.99%). Por lo que el procedimiento de eliminación de variables redundantes descrito en la subsección 7.1.8 conserva únicamente `CreditScoreRangeLower` como indicador de calidad crediticia. Dado que ambas variables son transformaciones lineales de la misma información, esta sustitución no supone pérdida de contenido informativo, si bien modifica la escala de interpretación del coeficiente estimado.

## 2. Transformación de la variable `Occupation`.

La variable `Occupation` recoge la ocupación declarada por el prestatario. Al tratarse de una variable categórica con un número elevado de categorías, su inclusión directa en el modelo podría generar demasiadas variables *dummy*<sup>5</sup> y aumentar innecesariamente la complejidad del modelo.

Por este motivo, se transformó en dos indicadores binarios:

- `Occupation_missing`: toma valor 1 cuando la ocupación del prestatario no está disponible y 0 en caso contrario.
- `Occupation_top5`: toma valor 1 cuando la ocupación del prestatario pertenece a una de las cinco ocupaciones más frecuentes de la muestra y 0 en caso contrario.

Con esta transformación se conserva información relevante sobre la disponibilidad de la ocupación y sobre la pertenencia a ocupaciones comunes, evitando introducir un número excesivo de categorías en el modelo.

## 3. Transformación de variables binarias.

Algunas variables de la base de datos original ya representan características dicotómicas del prestatario, aunque pueden aparecer codificadas en formato textual

---

<sup>5</sup>Una variable *dummy* o ficticia es una variable binaria que toma el valor 1 cuando la observación pertenece a una determinada categoría y 0 en caso contrario. Permite incorporar información cualitativa a un modelo de regresión. Para representar una variable categórica con  $m$  categorías se emplean  $m - 1$  variables *dummy*, omitiendo una de ellas como categoría de referencia para evitar la colinealidad perfecta con el término constante (Greene, 2012).

o booleano<sup>6</sup>. Para su inclusión en los modelos, estas variables se transformaron en indicadores binarios con valores 0 y 1.

En particular, se transformaron las siguientes variables:

- **IsBorrowerHomeowner**: indica si el prestatario es propietario de una vivienda. Toma valor 1 si el prestatario es propietario y 0 en caso contrario.
- **IncomeVerifiable**: indica si los ingresos declarados por el prestatario son verificables. Toma valor 1 si los ingresos pueden verificarse y 0 en caso contrario.

Estas variables resultan relevantes en el análisis de riesgo crediticio, ya que la propiedad de vivienda puede aproximar cierta estabilidad patrimonial, mientras que la verificabilidad de ingresos aporta información sobre la fiabilidad de la capacidad de pago declarada.

#### 4. Codificación ordinal de la variable **IncomeRange**.

La variable **IncomeRange** recoge el rango de ingresos anuales declarado por el prestatario. Dado que sus categorías presentan un orden natural, se transformó en una variable ordinal numérica, asignando valores crecientes a medida que aumenta el nivel de ingresos. La codificación utilizada se resume en la Tabla 7.

Tabla 7: Codificación ordinal de la variable **IncomeRange**

| Rango de ingresos            | Valor asignado                              |
|------------------------------|---------------------------------------------|
| \$0                          | 0                                           |
| \$1-24,999                   | 1                                           |
| \$25,000-49,999              | 2                                           |
| \$50,000-74,999              | 3                                           |
| \$75,000-99,999              | 4                                           |
| \$100,000+                   | 5                                           |
| Not displayed / Not employed | -1 (categoría de información no disponible) |

Esta transformación permite incorporar al modelo la información sobre el nivel de renta del prestatario respetando el orden económico de las categorías. En términos de riesgo crediticio, mayores niveles de ingresos pueden estar asociados con una mayor capacidad de pago, aunque su efecto debe interpretarse conjuntamente con otras variables como el endeudamiento o el importe del préstamo.

#### 5. Transformación de variables geográficas.

La variable **BorrowerState** recoge el estado de residencia del prestatario. Dado que se trata de una variable categórica con numerosas categorías, se optó por resumir su información mediante indicadores binarios.

En concreto, se construyeron las siguientes variables:

- **State\_high\_risk**: toma valor 1 si el estado de residencia del prestatario pertenece al grupo de estados con mayor tasa histórica de impago en la muestra y 0 en caso contrario.

<sup>6</sup>Un valor booleano es un tipo de dato que solo admite dos estados posibles, verdadero o falso, habitualmente representados en los lenguajes de programación como **True** y **False**. Su conversión a los valores numéricos 1 y 0 resulta necesaria para poder incorporar la variable a la estimación del modelo.

- **State\_missing**: toma valor 1 si la información sobre el estado de residencia no está disponible y 0 en caso contrario.

La variable **State\_high\_risk** permite recoger posibles diferencias geográficas en el comportamiento de impago, mientras que **State\_missing** permite controlar la ausencia de información geográfica sin eliminar observaciones adicionales.

Debe advertirse que la clasificación de estados de alto riesgo se construye a partir de la tasa histórica de impago calculada sobre el conjunto completo de la muestra, con anterioridad a la partición entre entrenamiento y prueba. En sentido estricto, este procedimiento introduce información de la variable dependiente correspondiente a observaciones que posteriormente formarán parte del conjunto de prueba. El efecto esperado es reducido, dado el elevado número de observaciones por estado y la escasa magnitud del coeficiente estimado para esta variable, pero constituye una desviación respecto de la práctica óptima, que consistiría en estimar dicha codificación únicamente sobre la muestra de entrenamiento.

## 6. Transformación de la variable **ListingCategory**.

La variable **ListingCategory** identifica la finalidad declarada del préstamo, como consolidación de deuda, financiación de negocio, gastos médicos, reformas del hogar u otras necesidades personales. Dado que esta variable es categórica, se transformó mediante variables **dummy** para las categorías más frecuentes.

Las variables **dummy** toman valor 1 cuando el préstamo pertenece a una determinada categoría y 0 en caso contrario. Esta transformación permite incorporar al modelo diferencias en el riesgo asociado a la finalidad del préstamo. Por ejemplo, un préstamo destinado a consolidación de deuda puede presentar un perfil de riesgo distinto al de un préstamo destinado a mejoras del hogar o financiación empresarial.

En conjunto, estas transformaciones permiten convertir la información original de la base de datos en un conjunto de variables explicativas numéricas, interpretables y adecuadas para la estimación de modelos de respuesta binaria. Además, el tratamiento aplicado reduce la dimensionalidad de las variables categóricas y facilita la posterior interpretación económica de los coeficientes estimados.

### 7.1.5. Limpieza avanzada de datos

Se aplican técnicas adicionales para mejorar la calidad del dataset.

#### Winsorización

La winsorización es una técnica de tratamiento de valores extremos que consiste en sustituir las observaciones situadas por debajo de un determinado percentil inferior y por encima de otro determinado percentil superior por el valor correspondiente a dichos percentiles. A diferencia del truncamiento, que elimina directamente esas observaciones, la winsorización las conserva limitando su valor, por lo que mantiene intacto el tamaño muestral y reduce al mismo tiempo la influencia desproporcionada que los valores atípicos pueden ejercer sobre la estimación de los parámetros (Svolba, 2006).

En este trabajo se aplica una winsorización simétrica a los percentiles 1 % y 99 %, umbrales habituales en la preparación de datos financieros, sobre las siguientes variables:

- **StatedMonthlyIncome**

- `DebtToIncomeRatio`
- `RevolvingCreditBalance`
- `LoanOriginalAmount`

## Transformaciones logarítmicas

Se crean nuevas variables logarítmicas:

- `log_StatedMonthlyIncome`: los ingresos mensuales declarados presentan una distribución muy concentrada en valores bajos con una cola derecha prolongada (asimetría de 1.70). Su expresión en logaritmos permite interpretar el efecto de la renta sobre el riesgo de impago en términos proporcionales.
- `log_LoanOriginalAmount`: el importe concedido presenta una asimetría de 1.05 y una fuerte concentración en determinados importes estándar de la plataforma. La transformación permite valorar el efecto de duplicar el principal en lugar del efecto de un incremento de una unidad monetaria.
- `log_RevolvingCreditBalance`: el saldo de crédito revolving es la variable más asimétrica de las tres (asimetría de 3.23), con un reducido número de prestatarios acumulando saldos muy elevados.

La transformación logarítmica responde a dos motivos. En primer lugar, comprime la cola derecha de distribuciones fuertemente asimétricas, reduciendo la influencia de los valores más elevados sobre la estimación. En segundo lugar, y desde el punto de vista económico, permite modelizar el efecto de estas variables en términos relativos y no absolutos: una variación de una unidad monetaria no tiene el mismo significado para un prestatario con ingresos reducidos que para uno con ingresos elevados, mientras que una variación porcentual sí resulta comparable entre ambos.

Debe precisarse, no obstante, que la reducción de la asimetría solo resulta efectiva en `log_LoanOriginalAmount`, cuya asimetría pasa de 1.05 a  $-0.24$ . En las otras dos variables la presencia de observaciones con valor cero —un 1.22 % en `StatedMonthlyIncome` y un 10.31 % en `RevolvingCreditBalance`— genera una acumulación en el extremo inferior de la distribución transformada, de modo que la asimetría no desaparece sino que cambia de signo. La transformación conserva en todo caso su justificación económica, si bien esta limitación debe tenerse presente al interpretar los coeficientes asociados.

## Eliminación de variables casi constantes

Se eliminan aquellas variables en las que más del 99 % de las observaciones presentan el mismo valor, ya que su escasa variabilidad impide que aporten capacidad explicativa al modelo. En la muestra utilizada, este criterio afecta únicamente a la variable `PercentFunded`, que recoge el porcentaje del importe solicitado que resultó efectivamente financiado y que toma el valor 1 —es decir, financiación completa— en el 99.25 % de las operaciones. Dado que la práctica totalidad de los préstamos de la muestra se financiaron íntegramente, la variable resulta prácticamente constante y se descarta del análisis.

### 7.1.6. Definición del conjunto de variables explicativas

Finalmente se define el conjunto de variables explicativas  $X$  y la variable dependiente  $Y$ .

Finalmente, se define el conjunto de variables explicativas  $X$ , formado por las 42 variables resultantes del proceso descrito, y la variable dependiente  $Y$ , correspondiente al indicador binario de impago construido en el apartado 7.1.1.

### 7.1.7. Análisis exploratorio de los datos

Antes de estimar los modelos se realiza un análisis exploratorio con el objetivo de estudiar la distribución de las variables y detectar posibles características relevantes para la modelización, como asimetrías, concentración de valores, presencia de valores extremos o diferencias en escala entre variables. Esta fase resulta especialmente importante en problemas de credit scoring, ya que permite comprender mejor la estructura de los datos antes de aplicar modelos econométricos y técnicas de selección de variables.




Figura 6: Distribución de variables numéricas seleccionadas. (a) *LoanOriginalAmount*; (b) *BorrowerRate*; (c) *BorrowerAPR*; (d) *ProsperScore*; (e) *DebtToIncomeRatio*; (f) *FICOScore*.

La Figura 6 presenta la distribución de seis variables numéricas seleccionadas. Estas variables fueron escogidas por su relevancia y por su potencial capacidad explicativa en la estimación de la probabilidad de impago. Aún así, durante el trabajo de código, se han realizado histogramas de todas las variables existentes en la base de datos.

En primer lugar, la variable *LoanOriginalAmount* refleja el importe inicial del préstamo concedido. Su distribución muestra una elevada concentración en determinados niveles de financiación, lo que sugiere la existencia de importes estándar dentro de la plataforma.

Las variables *BorrowerRate* y *BorrowerAPR*, recogidas en la Figura 6 (b) y (c), reflejan el coste del préstamo para el prestatario. Ambas presentan distribuciones unimodales y aproximadamente simétricas en torno a su valor central: la tasa anual equivalente se sitúa en una media del 21.82 % con una mediana del 20.84 %, mientras que el tipo de interés aplicado promedia el 19.28 %. La mayor concentración de operaciones se produce en el intervalo comprendido entre el 15.4 % y el 17.9 %, que agrupa 13 643 préstamos, y algo más del 43 % de la cartera se sitúa entre el 15 % y el 25 %. La similitud entre ambas

distribuciones anticipa la elevada correlación existente entre ellas, que alcanza un valor de 0.99, dado que miden dimensiones muy próximas del precio del crédito.

La variable *ProsperScore* que aparece, recogida en la Figura 6 (d), representa una medida del perfil de riesgo del prestatario y presenta una distribución discreta.

Por su parte, la variable *DebtToIncomeRatio*, recogida en la Figura 6 (e), muestra una distribución asimétrica a la derecha, con una mayor concentración en valores bajos y una cola hacia valores elevados, lo que es consistente con la presencia de prestatarios con altos niveles de endeudamiento relativo.

Finalmente, la variable *FICOScore*, representada en la Figura 6 (f), presenta una fuerte concentración en valores medios-altos, lo que indica que la mayoría de los prestatarios poseen un nivel de calidad crediticia relativamente alto.

Conviene anticipar que tres de las variables representadas en la Figura 6 —*LoanOriginalAmount* en el panel (a), *BorrowerRate* en el (b) y *FICOScore* en el (f)— no forman parte del conjunto final de regresores, al haber sido descartadas en el proceso de eliminación de variables altamente correlacionadas descrito en el apartado 7.1.8. Su inclusión en el análisis exploratorio responde a su relevancia económica y resulta útil para caracterizar la estructura de los datos en esta fase previa.

En conjunto, el análisis gráfico permite extraer varias conclusiones preliminares. En primer lugar, muchas variables utilizadas en el modelo no siguen distribuciones simétricas ni normales, lo que refuerza la conveniencia de utilizar modelos adecuados para variables binarias y técnicas de transformación en determinadas variables financieras. En segundo lugar, se observan posibles problemas de asimetría concentración y correlación entre algunas variables, lo que justifica las etapas posteriores de limpieza, transformación y selección de variables. Por tanto, este análisis exploratorio constituye un paso previo necesario para garantizar una modelización más robusta y consistente del riesgo crediticio.

Este tipo de análisis es fundamental en credit scoring, ya que permite anticipar problemas de modelización como la multicolinealidad o la presencia de distribuciones no lineales (James et al., 2013).

#### **7.1.8. Análisis de correlación**

Con el objetivo de analizar la relación lineal entre las variables explicativas, se calcula la matriz de correlación de Pearson, presentada en la Figura 7. Este análisis permite identificar posibles relaciones de dependencia entre variables y detectar problemas de multicolinealidad, que pueden afectar a la estabilidad de los modelos estimados (Greene, 2012).

Para mejorar la interpretación visual de las relaciones entre variables, se reordena la matriz de correlación mediante un procedimiento de agrupamiento jerárquico. La Figura 8 permite identificar grupos de variables con patrones de correlación similares, facilitando la detección de posibles redundancias en el conjunto de variables explicativas.

Adicionalmente, se identifican los pares de variables con correlación elevada, considerando como umbral un valor absoluto superior a 0.7. Este análisis permite detectar posibles problemas de multicolinealidad y redundancia en la información contenida en el modelo. En particular, se observa una elevada correlación entre variables relacionadas con el coste del préstamo, lo que resulta consistente desde el punto de vista económico y justifica la

necesidad de aplicar criterios de selección de variables en etapas posteriores. El La Tabla 8 recoge los pares de variables que superan dicho umbral.




Figura 7: Matriz inicial de correlaciones




Figura 8: Matriz de correlación ordenada mediante clustering




Figura 9: Matriz de correlación de las variables con  $|r| \geq 0.7$

Tabla 8: Pares de variables con correlación fuerte ( $|r| \geq 0.7$ )

| Variable 1                       | Variable 2                 | Correlación absoluta |
|----------------------------------|----------------------------|----------------------|
| CreditScoreRangeUpper            | FICOScore                  | 0.999979             |
| CreditScoreRangeLower            | FICOScore                  | 0.999978             |
| CreditScoreRangeLower            | CreditScoreRangeUpper      | 0.999914             |
| BorrowerRate                     | LenderYield                | 0.999201             |
| BorrowerAPR                      | BorrowerRate               | 0.989525             |
| BorrowerAPR                      | LenderYield                | 0.989030             |
| CurrentCreditLines               | OpenCreditLines            | 0.967992             |
| LoanOriginalAmount               | MonthlyLoanPayment         | 0.929328             |
| LoanOriginalAmount               | log_LoanOriginalAmount     | 0.923966             |
| MonthlyLoanPayment               | log_LoanOriginalAmount     | 0.868880             |
| TotalCreditLinespast7years       | TotalTrades                | 0.852880             |
| OpenCreditLines                  | OpenRevolvingAccounts      | 0.834246             |
| CurrentCreditLines               | OpenRevolvingAccounts      | 0.804068             |
| OpenRevolvingMonthlyPayment      | RevolvingCreditBalance     | 0.795127             |
| TradesNeverDelinquent_percentage | log_RevolvingCreditBalance | 0.744343             |
| CurrentCreditLines               | TotalTrades                | 0.742313             |
| InquiriesLast6Months             | TotalInquiries             | 0.730893             |
| Recommendations                  | InvestmentFromFriendsCount | 0.719026             |
| OpenCreditLines                  | TotalTrades                | 0.706273             |

Adicionalmente, la Figura 9 representa la submatriz de correlaciones restringida a aquellas variables que superan dicho umbral, lo que permite visualizar con mayor detalle los bloques de redundancia detectados. En particular, se observa una elevada correlación entre algunas variables relacionadas con el coste del préstamo, como *BorrowerRate* y *BorrowerAPR*, lo que indica la presencia de redundancia en la información. Este resultado es coherente desde el punto de vista económico, ya que ambas variables capturan dimensiones muy similares del precio del crédito.

La existencia de correlaciones elevadas puede generar problemas de multicolinealidad en los modelos estimados, afectando a la estabilidad de los coeficientes y a su interpretación. Por esta razón, resulta necesario aplicar métodos de selección de variables, como los procedimientos forward y backward stepwise, con el objetivo de evitar la inclusión simultánea de variables altamente correlacionadas.

En conjunto, el análisis exploratorio y de correlaciones permite identificar la presencia de relaciones lineales significativas entre algunas variables, así como patrones de distribución no normales. Estos resultados justifican la aplicación posterior de técnicas de transformación y selección de variables, con el objetivo de mejorar la robustez y capacidad predictiva de los modelos de credit scoring.

Tras identificar y eliminar las variables numéricas altamente correlacionadas, se recalculó la matriz de correlaciones con el objetivo de verificar que no persistieran relaciones lineales fuertes entre las variables seleccionadas. Como se observa en la Figura 10, la matriz resultante no presenta correlaciones absolutas elevadas, situándose todos los pares por debajo del umbral de 0.7 utilizado como criterio de eliminación, lo que confirma que el problema de multicolinealidad ha sido mitigado.




Figura 10: Matriz de correlación tras eliminación de variables

## 7.2. Bondad de ajuste, diseño de validación y métricas de evaluación

Una vez finalizado el proceso de depuración, transformación y selección de variables, se procede a la estimación y evaluación de los modelos de clasificación binaria propuestos. En particular, se analizan especificaciones `logit` y `probit` dentro del marco de los GLM, utilizando los procedimientos de selección de variables mediante los procesos *forward-stepwise* y *backward-stepwise*.

En la construcción de modelos predictivos no resulta suficiente evaluar el ajuste sobre los datos utilizados en la estimación. Un modelo puede presentar un rendimiento elevado en la muestra de entrenamiento y, sin embargo, mostrar una capacidad predictiva limitada cuando se aplica a nuevas observaciones. Por esta razón, en la literatura de aprendizaje estadístico se distingue entre evaluación dentro de muestra (*in-sample*) y fuera de muestra (*out-of-sample*), siendo esta última esencial para valorar la capacidad de generalización del modelo (Hastie et al., 2009).

Con este objetivo, la base de datos se divide en dos subconjuntos: un conjunto de entrenamiento, que representa el 80 % de las observaciones y se utiliza para estimar los parámetros de los modelos, y un conjunto de prueba independiente, que representa el 20 % restante y se emplea exclusivamente para evaluar el rendimiento predictivo sobre observaciones no utilizadas durante la estimación.

La elección de una partición 80/20 responde a una práctica habitual en los procesos de

validación de modelos predictivos, ya que permite disponer de una muestra suficientemente amplia para el entrenamiento del modelo, manteniendo al mismo tiempo un conjunto independiente de observaciones para evaluar su capacidad de generalización (Hastie et al., 2009). Este enfoque permite detectar posibles problemas de sobreajuste (*overfitting*) y proporciona una medida más realista de la utilidad práctica del modelo en contextos reales de concesión de crédito, donde el interés principal reside en clasificar correctamente nuevas solicitudes.

En términos operativos, la partición se realizó de forma aleatoria y estratificada según la variable dependiente, con el fin de preservar la proporción de impagos en ambos subconjuntos, y fijando una semilla aleatoria que garantiza la reproducibilidad exacta de los resultados. La muestra de entrenamiento resultante contiene 89.998 observaciones y la de prueba 22.500.

Dado que la variable dependiente adopta valor 1 cuando el préstamo incurre en impago y 0 en caso contrario, el problema se formula como una tarea de clasificación binaria. A partir de las probabilidades estimadas por cada modelo, la clasificación final se obtiene utilizando un umbral de decisión de 0.5. Es decir, una observación se clasifica como impago cuando la probabilidad estimada es superior o igual a dicho valor. Aunque se adopta el umbral convencional de 0.5 por simplicidad expositiva, en aplicaciones reales este puede ajustarse en función del coste relativo entre falsos positivos y falsos negativos.

Para evaluar el rendimiento predictivo se utilizan las siguientes métricas:

- *Accuracy*: mide la proporción total de predicciones correctas sobre el total de observaciones.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (17)$$

- *Precision*: indica la proporción de predicciones positivas correctas sobre el total de predicciones positivas realizadas por el modelo.

$$Precision = \frac{TP}{TP + FP} \quad (18)$$

- *Recall*: mide la capacidad del modelo para identificar correctamente los casos positivos, es decir, los prestatarios en situación de impago.

$$Recall = \frac{TP}{TP + FN} \quad (19)$$

- *F1-score*: combina precisión y recall en una única medida, proporcionando un equilibrio entre ambas.

$$F1 = 2 \cdot \frac{Precision \times Recall}{Precision + Recall} \quad (20)$$

- *AUC (Área bajo la curva ROC)*: evalúa la capacidad del modelo para discriminar entre las clases, independientemente del umbral de clasificación Brown and Mues (2012). La curva ROC representa la relación entre la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR):

$$TPR = \frac{TP}{TP + FN} \quad (21)$$

$$FPR = \frac{FP}{FP + TN} \quad (22)$$

donde:

- *TP (True Positives)*: impagos correctamente identificados.
- *TN (True Negatives)*: prestatarios solventes correctamente clasificados.
- *FP (False Positives)*: prestatarios solventes clasificados erróneamente como impago.
- *FN (False Negatives)*: impagos no detectados por el modelo.

En problemas de riesgo crediticio caracterizados por un desbalanceo entre clases, métricas como Recall, F1-score y ROC-AUC suelen resultar más informativas que la Accuracy, ya que permiten evaluar con mayor precisión la capacidad del modelo para detectar prestatarios en situación de impago.

## 8. Estimación de modelos y análisis de resultados

### 8.1. GLM: logit y probit

Tras aplicar los procedimientos de selección de variables descritos en la sección 4, se estiman cuatro especificaciones GLM, resultantes de combinar las dos funciones de enlace consideradas con los dos algoritmos secuenciales empleados:

- **Logit backward**, que retiene 39 variables explicativas.
- **Logit forward**, que retiene 40 variables explicativas.
- **Probit backward**, que retiene 38 variables explicativas.
- **Probit forward**, que retiene 38 variables explicativas.

Los cuatro modelos convergen a especificaciones muy similares. En el caso del **logit**, tanto el procedimiento forward como el backward seleccionan prácticamente el mismo conjunto de predictores; la única diferencia es que el forward retiene además la variable **EmploymentStatus\_Self-employed**. En el caso del **probit**, ambos procedimientos difieren únicamente en dos variables: el backward incluye **log\_StatedMonthlyIncome** y el forward **EmploymentStatus\_Self-employed**. Esta coincidencia casi total confirma la robustez del proceso de selección, ya que las variables con mayor capacidad explicativa son identificadas de forma consistente con independencia del algoritmo secuencial empleado.

La Tabla 9 recoge las variables incluidas en el modelo **logit forward** junto con sus coeficientes estimados y p-valores asociados. La práctica totalidad de las variables retenidas resulta estadísticamente significativa a los niveles habituales. La única excepción es **EmploymentStatus\_Self-employed**, cuyo p-valor (0.87) indica ausencia de significatividad; no es casualidad que se trate precisamente de la única variable en la que difieren las especificaciones forward y backward del **logit**, ya que el procedimiento backward la elimina por su escasa contribución al ajuste. Su permanencia en el modelo forward se debe a que, una vez incorporada en una fase temprana del algoritmo, la

inclusión posterior de otras variables reduce su relevancia sin que llegue a ser descartada. Este comportamiento ilustra una de las diferencias conocidas entre ambos procedimientos secuenciales.

Desde el punto de vista de la interpretación económica, los signos estimados resultan coherentes con la teoría del riesgo crediticio. La expresión de los coeficientes en términos de *odds ratios* facilita esta lectura, al permitir cuantificar el efecto de cada variable sobre la razón de probabilidades de impago.

La variable **BorrowerAPR**, que recoge el coste del crédito, presenta el efecto de mayor magnitud: un incremento de un punto porcentual en la tasa anual equivalente eleva la razón de probabilidades de impago en un 7.6 %, de modo que una diferencia de cinco puntos porcentuales la multiplica por 1.44. Este resultado resulta económicamente coherente y admite una doble lectura: por un lado, un mayor coste financiero incrementa la carga de la deuda y deteriora la capacidad de pago; por otro, el tipo aplicado incorpora la valoración del riesgo realizada por la plataforma en el momento de la concesión, por lo que actúa parcialmente como indicador del perfil de riesgo del prestatario.

En sentido contrario, **CreditScoreRangeLower**, asociada a la calidad crediticia, presenta un odds ratio de 0.9976 por punto de puntuación; un incremento de 100 puntos reduce la razón de probabilidades de impago en un 21.3 %. Del mismo modo, **IncomeVerifiable** reduce dicha razón en un 24.8 %, lo que confirma que la verificabilidad de los ingresos declarados constituye un indicador relevante de la fiabilidad de la información aportada por el solicitante.

Entre las variables asociadas a un mayor riesgo destacan los indicadores de incidencias previas: **CurrentDelinquencies** incrementa la razón de probabilidades de impago en un 9.3 % por cada retraso adicional y **PublicRecordsLast10Years** en un 10.2 % por cada registro público. Asimismo, **DebtToIncomeRatio** eleva dicha razón en un 3.4 % por cada décima adicional de ratio de endeudamiento, y **Term** en un 18.4 % por cada año adicional de duración del préstamo, lo que resulta consistente con la mayor exposición temporal al riesgo de las operaciones a plazo más largo. El importe concedido opera en la misma dirección: duplicar el principal del préstamo incrementa la razón de probabilidades de impago en un 28.8 %.

Merece una mención específica el comportamiento de los indicadores de información ausente. Las variables **Occupation\_missing**, **State\_missing** y **EmploymentStatus\_Not available** presentan coeficientes negativos de magnitud considerable, reduciendo la razón de probabilidades de impago entre un 57 % y un 79 %. Estos valores no admiten una interpretación económica directa en términos de solvencia, sino que reflejan diferencias en los procedimientos de recogida de información a lo largo del período muestral. Su interpretación debe realizarse, por tanto, con cautela, en línea con las limitaciones señaladas en la sección ??.

Tabla 9: Variables, coeficientes, odds ratios y p-valores del modelo Logit Forward

| Variable                       | Coeficiente | Odds ratio          | p-valor |
|--------------------------------|-------------|---------------------|---------|
| const                          | -2.1161     | 0.1205              | 0.0000  |
| BorrowerAPR                    | 7.2995      | 1.0757 <sup>†</sup> | 0.0000  |
| ProsperScore                   | -0.0153     | 0.9848              | 0.0036  |
| LoanNumber                     | -0.0000     | 1.0000 <sup>‡</sup> | 0.0000  |
| State_missing                  | -0.8414     | 0.4311              | 0.0000  |
| log_LoanOriginalAmount         | 0.3648      | 1.4402              | 0.0000  |
| InquiriesLast6Months           | 0.0765      | 1.0795              | 0.0000  |
| StatedMonthlyIncome            | -0.0001     | 0.9999              | 0.0000  |
| CurrentDelinquencies           | 0.0885      | 1.0925              | 0.0000  |
| TradesOpenedLast6Months        | 0.0995      | 1.1046              | 0.0000  |
| ListingCat_0                   | -0.4923     | 0.6112              | 0.0000  |
| CreditScoreRangeLower          | -0.0024     | 0.9976              | 0.0000  |
| Term                           | 0.0141      | 1.0142              | 0.0000  |
| EmploymentStatus_Self-employed | 0.0096      | 1.0096              | 0.8739  |
| Occupation_missing             | -1.5687     | 0.2083              | 0.0000  |
| IsBorrowerHomeowner            | 0.1758      | 1.1922              | 0.0000  |
| PublicRecordsLast10Years       | 0.0969      | 1.1018              | 0.0000  |
| ListingCat_1                   | -0.1902     | 0.8268              | 0.0000  |
| EmploymentStatus_Not available | -1.1639     | 0.3123              | 0.0000  |
| EmploymentStatus_Full-time     | -0.2963     | 0.7436              | 0.0000  |
| EmploymentStatus_Part-time     | -0.6302     | 0.5325              | 0.0000  |
| IncomeRange_num                | -0.0720     | 0.9305              | 0.0000  |
| Recommendations                | -0.1682     | 0.8452              | 0.0000  |
| BankcardUtilization            | -0.2739     | 0.7604              | 0.0000  |
| OpenRevolvingMonthlyPayment    | 0.0002      | 1.0002              | 0.0000  |
| OpenCreditLines                | -0.0226     | 0.9777              | 0.0000  |
| DelinquenciesLast7Years        | -0.0046     | 0.9954              | 0.0000  |
| Investors                      | 0.0006      | 1.0006              | 0.0000  |
| ListingCat_6                   | -0.3482     | 0.7060              | 0.0000  |
| ListingCat_7                   | -0.1920     | 0.8253              | 0.0000  |
| EmploymentStatus_Other         | 0.2774      | 1.3197              | 0.0001  |
| Occupation_top5                | -0.0656     | 0.9365              | 0.0034  |
| AvailableBankcardCredit        | -0.0000     | 1.0000 <sup>‡</sup> | 0.0081  |
| IncomeVerifiable               | -0.2844     | 0.7525              | 0.0000  |
| DebtToIncomeRatio              | 0.3321      | 1.3939              | 0.0001  |
| log_StatedMonthlyIncome        | 0.0274      | 1.0278              | 0.0159  |
| PublicRecordsLast12Months      | -0.1551     | 0.8563              | 0.0187  |
| AmountDelinquent               | -0.0000     | 1.0000 <sup>‡</sup> | 0.0192  |
| ListingCat_2                   | -0.1102     | 0.8957              | 0.0323  |
| CurrentlyInGroup               | -0.0689     | 0.9334              | 0.0339  |
| State_high_risk                | 0.0512      | 1.0525              | 0.0416  |

*Nota.* El odds ratio se obtiene como  $e^{\hat{\beta}}$  e indica la variación multiplicativa de la razón de probabilidades de impago ante un incremento unitario de la variable, manteniendo constante el resto de factores. Valores superiores a la unidad indican un aumento del riesgo y valores inferiores, una reducción.

<sup>†</sup> Dado que **BorrowerAPR** se expresa en tanto por uno, se reporta el odds ratio correspondiente a un incremento de un punto porcentual ( $e^{0.01\hat{\beta}}$ ), interpretativamente más adecuado que el incremento unitario.

<sup>‡</sup> Variables medidas en unidades monetarias o en escalas de gran magnitud, para las que el efecto de un incremento unitario resulta indistinguible de la unidad; su interpretación requiere considerar incrementos de mayor tamaño.

## 8.2. SMOTE y Random Forest

Como extensión al análisis basado en GLM, se consideran dos alternativas complementarias frecuentemente utilizadas en problemas de clasificación con datos desbalanceados.

La primera es la técnica SMOTE, descrita en la sección 5, que genera observaciones sintéticas de la clase minoritaria mediante interpolación entre instancias próximas con el fin de equilibrar la distribución de clases. En este trabajo, SMOTE se aplica únicamente sobre la muestra de entrenamiento, manteniendo intacto el conjunto de prueba, de forma que la evaluación fuera de muestra siga reflejando la distribución real de los datos. Sobre el conjunto balanceado se estima un modelo de regresión logística.

Debe precisarse que esta especificación no coincide exactamente con la de los modelos GLM de los apartados anteriores. El modelo estimado sobre datos balanceados incorpora la totalidad de las variables explicativas disponibles, sin aplicar previamente el procedimiento de selección secuencial, y se estima mediante regresión logística regularizada con penalización  $L_2$  sobre variables previamente estandarizadas. En consecuencia, las diferencias observadas frente a los modelos `logit` y `probit` no son atribuibles de forma exclusiva al tratamiento del desbalance, sino también a la especificación y al método de estimación empleados. Esta circunstancia debe tenerse presente al interpretar los resultados del apartado 8.3.3.

La segunda alternativa es el algoritmo Random Forest, descrito en la sección 6. Su inclusión permite valorar si un modelo de aprendizaje automático más flexible aporta mejoras predictivas relevantes frente a los modelos lineales.

Adicionalmente, se estima una versión combinada del algoritmo sobre datos balanceados mediante SMOTE, conforme a la segunda de las estrategias descritas en el apartado 6.4, con el fin de evaluar el efecto conjunto del balanceo de datos y de un algoritmo no paramétrico.

## 8.3. Aplicación práctica de los diferentes modelos

Una vez estimadas las especificaciones descritas en los apartados anteriores, se procede a su evaluación conjunta. El análisis abarca los siete modelos considerados en el trabajo: las cuatro especificaciones GLM resultantes de combinar ambas funciones de enlace con los dos procedimientos de selección secuencial, el modelo `logit` estimado sobre datos balanceados mediante SMOTE, y las dos variantes del algoritmo Random Forest. Todos ellos se evalúan bajo un umbral de clasificación de 0.5, primero sobre la muestra de entrenamiento y después sobre la muestra de prueba.

### 8.3.1. Ajuste dentro de muestra

La Tabla 10 recoge el ajuste de los siete modelos sobre el conjunto de entrenamiento, formado por 89 998 observaciones.

Tabla 10: Ajuste de los siete modelos en la muestra de entrenamiento

| Modelo          | Accuracy | Precision | Recall | F1-score | ROC-AUC |
|-----------------|----------|-----------|--------|----------|---------|
| Logit backward  | 0.8615   | 0.6318    | 0.2793 | 0.3874   | 0.8582  |
| Logit forward   | 0.8615   | 0.6318    | 0.2793 | 0.3874   | 0.8582  |
| Probit backward | 0.8617   | 0.6409    | 0.2680 | 0.3779   | 0.8584  |
| Probit forward  | 0.8617   | 0.6408    | 0.2686 | 0.3785   | 0.8585  |
| Logit + SMOTE   | 0.7416   | 0.3589    | 0.8232 | 0.4999   | 0.8565  |
| Random Forest   | 1.0000   | 1.0000    | 1.0000 | 1.0000   | 1.0000  |
| RF + SMOTE      | 1.0000   | 1.0000    | 1.0000 | 1.0000   | 1.0000  |

Las cuatro especificaciones GLM presentan un comportamiento prácticamente idéntico, con valores de *accuracy* en torno al 86.2 % y de ROC-AUC próximos a 0.858. Entre ellas, las especificaciones **probit** alcanzan los menores criterios de información (AIC de 55 698.05 y BIC de 56 064.94 en el caso del *backward*), si bien las diferencias respecto al **logit** son de escasa magnitud. Conviene recordar que, dado que la tasa de impago se sitúa en el 15.68 %, un clasificador que asignase la categoría de no impago a la totalidad de las observaciones alcanzaría una *accuracy* del 84.3 %, por lo que la mejora aportada debe valorarse frente a esa referencia.

El modelo estimado sobre datos balanceados mediante SMOTE presenta un patrón distinto: reduce la *accuracy* hasta el 74.16 % pero eleva el *recall* hasta 0.8232, en línea con el efecto de descalibración descrito en el apartado 8.2.

Finalmente, ambas variantes de Random Forest alcanzan valores perfectos en todas las métricas. Este resultado no refleja una capacidad predictiva superior, sino la memorización completa del conjunto de entrenamiento: al construirse los árboles sin restricción de profundidad ni de tamaño mínimo de nodo terminal, el ensamble puede reproducir de forma exacta la clase de cada observación utilizada en la estimación. Se trata de la manifestación más clara del fenómeno de sobreajuste descrito en el apartado 4.1, y evidencia que el ajuste dentro de muestra no constituye por sí solo un criterio válido de comparación entre modelos.

### 8.3.2. Rendimiento visual dentro de muestra

Las Figuras 11 y 12 representan gráficamente el comportamiento de los siete modelos sobre la muestra de entrenamiento.




Figura 11: Curvas ROC de los siete modelos en la muestra de entrenamiento




Figura 12: Matrices de confusión de los siete modelos en la muestra de entrenamiento

Las curvas ROC de las cinco especificaciones lineales se superponen prácticamente en su totalidad, lo que confirma la similitud de su capacidad discriminante con independencia de la función de enlace, del algoritmo de selección o de la aplicación de SMOTE (Fawcett, 2006). Las dos variantes de Random Forest, por el contrario, describen un ángulo recto que alcanza el vértice superior izquierdo, correspondiente a una clasificación perfecta.

Las matrices de confusión permiten cuantificar este comportamiento. Los modelos GLM clasifican correctamente en torno a 73 600 operaciones no impagadas, pero detectan menos de 4 000 de los 14 114 impagos existentes. El modelo con SMOTE invierte este equilibrio, identificando 11 619 impagos a costa de elevar los falsos positivos hasta 20 756. Las variantes de Random Forest no cometen ningún error de clasificación, lo que confirma la

memorización señalada en el apartado anterior. Esta descomposición resulta especialmente relevante en riesgo crediticio, donde clasificar como solvente a un prestatario que finalmente incurre en impago suele tener un coste muy superior al de rechazar erróneamente una operación solvente (Bahnsen et al., 2014).

### 8.3.3. Capacidad predictiva de los modelos

La evaluación fuera de muestra se realiza sobre el conjunto de prueba, formado por 22 500 observaciones no utilizadas durante la estimación. La Tabla 11 recoge los resultados obtenidos.

Tabla 11: Capacidad predictiva de los siete modelos en la muestra de prueba

| Modelo          | Accuracy | Precision | Recall | F1-score | ROC-AUC | Interpretabilidad |
|-----------------|----------|-----------|--------|----------|---------|-------------------|
| Logit backward  | 0.8632   | 0.6502    | 0.2766 | 0.3881   | 0.8591  | Alta              |
| Logit forward   | 0.8633   | 0.6507    | 0.2771 | 0.3887   | 0.8591  | Alta              |
| Probit backward | 0.8635   | 0.6610    | 0.2658 | 0.3791   | 0.8594  | Alta              |
| Probit forward  | 0.8632   | 0.6594    | 0.2644 | 0.3774   | 0.8594  | Alta              |
| Logit + SMOTE   | 0.7425   | 0.3593    | 0.8189 | 0.4994   | 0.8576  | Alta              |
| Random Forest   | 0.8605   | 0.6653    | 0.2230 | 0.3340   | 0.8643  | Baja              |
| RF + SMOTE      | 0.8604   | 0.5929    | 0.3508 | 0.4408   | 0.8590  | Baja              |

El resultado más relevante es el contraste entre ambas tablas. Los modelos de Random Forest, que alcanzaban un ajuste perfecto en entrenamiento, obtienen fuera de muestra una *accuracy* del 86.05 % y un *recall* de 0.2230, el más bajo de los siete modelos. Las especificaciones GLM, en cambio, mantienen prácticamente inalteradas sus métricas entre ambas muestras, con variaciones del orden de la milésima. Esta estabilidad confirma la ausencia de sobreajuste en los modelos lineales y justifica que la comparación entre metodologías deba realizarse siempre sobre observaciones no utilizadas en la estimación (Shmueli, 2010).

Atendiendo a cada criterio por separado, Random Forest obtiene el mayor valor de ROC-AUC (0.8643), lo que indica la mejor capacidad de ordenación de los prestatarios según su riesgo relativo, si bien la diferencia frente a las especificaciones GLM se sitúa en la quinta milésima. El modelo *logit* con SMOTE alcanza con diferencia el mayor *recall* (0.8189), detectando cuatro de cada cinco impagos, a costa de reducir la *precision* hasta 0.3593. Los modelos *probit* obtienen la mayor *accuracy* y las especificaciones *logit* el mejor equilibrio entre *precision* y *recall* dentro del grupo de modelos no balanceados. Finalmente, RF con SMOTE ofrece una posición intermedia, con el segundo mejor F1-score del conjunto.

Las Figuras 13 y 14 representan estos resultados sobre la muestra de prueba.




Figura 13: Curvas ROC de los siete modelos en la muestra de prueba




Figura 14: Matrices de confusión de los siete modelos en la muestra de prueba

A diferencia de lo observado dentro de muestra, las siete curvas ROC se superponen ahora en un rango muy estrecho, sin que ninguna especificación domine claramente al resto. Las matrices de confusión muestran que los modelos GLM y Random Forest detectan entre 787 y 978 de los 3 529 impagos presentes en la muestra de prueba, mientras que el modelo con SMOTE identifica 2 890 a costa de clasificar erróneamente 5 154 operaciones solventes.

Las Figuras 15 y 16 sintetizan la comparación fuera de muestra en términos de ROC-AUC y de *recall*, las dos métricas más relevantes en un problema de clases desbalanceadas.




Figura 15: Comparación de ROC-AUC entre modelos en la muestra de prueba




Figura 16: Comparación de *recall* entre modelos en la muestra de prueba

Ambas figuras ilustran la conclusión central del análisis: las diferencias en capacidad discriminante entre los siete modelos son mínimas, mientras que las diferencias en capacidad de detección de impagos son muy amplias. Dicho de otro modo, la elección del modelo apenas altera la ordenación de los prestatarios según su riesgo, pero sí determina de forma decisiva cuántos impagos se identifican bajo un umbral dado.

Tabla 12: Trade-off entre modelos

| Modelo        | ROC-AUC  | Recall   | Interpretabilidad |
|---------------|----------|----------|-------------------|
| Logit         | Alta     | Media    | Muy alta          |
| Probit        | Alta     | Media    | Muy alta          |
| Logit + SMOTE | Buena    | Muy alta | Muy alta          |
| RF            | Muy alta | Baja     | Baja              |
| RF + SMOTE    | Buena    | Media    | Baja              |

La Tabla 12 resume los compromisos observados entre capacidad predictiva, detección de impagos e interpretabilidad. No existe una alternativa universalmente superior: si se prioriza la interpretabilidad y la estabilidad, los modelos **logit** y **probit** resultan preferibles; si el objetivo es maximizar la detección de impagos, el **logit** con SMOTE es la opción más adecuada; y si se busca la máxima capacidad discriminante, Random Forest obtiene el mejor resultado, aunque con una ventaja marginal y a costa de la transparencia. La decisión final depende, por tanto, del objetivo operativo y del marco regulatorio de la entidad financiera.

## 9. Conclusiones

El presente ha analizado la aplicación de distintos modelos estadísticos y de machine learning en el ámbito del credit scoring, con especial atención a tres cuestiones centrales en la modelización moderna del riesgo crediticio: la capacidad predictiva de los modelos, el tratamiento del desbalanceo de clases y el equilibrio entre rendimiento e interpretabilidad.

A partir de una base de datos real de préstamos, se desarrolló un proceso completo de preparación de datos, construcción de la variable objetivo, selección de variables, estimación de modelos y validación empírica dentro y fuera de muestra. Este enfoque ha permitido comparar distintas metodologías bajo un mismo marco analítico y extraer conclusiones relevantes tanto desde una perspectiva técnica como aplicada.

En primer lugar, los resultados obtenidos muestran que los GLM, concretamente las especificaciones **logit** y **probit**, continúan ofreciendo un rendimiento muy competitivo en problemas de riesgo crediticio. Las métricas alcanzadas en términos de precisión y ROC-AUC evidencian una capacidad predictiva sólida, mientras que la similitud entre resultados dentro y fuera de muestra sugiere una adecuada capacidad de generalización y ausencia de sobreajuste relevante.

En segundo lugar, no se observaron diferencias sustanciales entre los modelos **logit** y **probit**, ni tampoco entre los procedimientos de selección de variables forward stepwise y backward stepwise. Este resultado refuerza la idea de que, en aplicaciones prácticas de clasificación binaria, distintas especificaciones econométricas pueden conducir a similares resultados cuando la preparación de datos y la selección de variables se realizan de forma rigurosa.

En tercer lugar, el análisis confirmó la relevancia del problema de los datos desbalanceados. La aplicación de SMOTE mejoró notablemente la capacidad de detección de prestatarios en situación de impago dentro de muestra, especialmente en términos de recall. No obstante, esta mejora vino acompañada de una reducción en otras métricas como la precisión, lo que evidencia la existencia de compromisos entre distintos objetivos predictivos.

En cuarto lugar, los modelos basados en Random Forest mostraron una elevada capacidad discriminatoria global, alcanzando los mejores resultados en determinadas métricas como ROC-AUC. Sin embargo, estas mejoras no fueron suficientemente amplias como para invalidar la competitividad de los modelos lineales tradicionales, especialmente cuando se incorpora al análisis la dimensión de interpretabilidad, y sobretodo cuando se trabaja con datos fuera de muestra.

En conjunto, la evidencia empírica obtenida permite concluir que no existe un modelo universalmente superior en todas las dimensiones relevantes. La elección óptima depende del contexto operativo, del coste relativo de los errores de clasificación y de los requisitos regulatorios exigidos a la entidad financiera.

Como toda investigación aplicada, este estudio presenta determinadas limitaciones que conviene reconocer. En primer lugar, la definición de la variable objetivo se ve afectada por la censura descrita en el apartado 7.1.1: los préstamos vigentes en el momento de recogida de los datos se clasifican como no impago con independencia de su evolución posterior. Como consecuencia, la tasa de impago observada difiere sustancialmente entre cohortes de originación y los modelos estimados capturan, junto al riesgo de crédito propiamente dicho, un componente asociado a la antigüedad de la operación.

En segundo lugar, tanto la selección de variables como la estimación de los modelos se han realizado sobre una única partición aleatoria entrenamiento-prueba. Los coeficientes obtenidos y las métricas de evaluación están condicionados, por tanto, a esa división concreta de la muestra. A ello se añade que los errores estándar habituales no incorporan la variabilidad asociada al propio procedimiento de selección secuencial, que se ejecuta una sola vez sobre los mismos datos empleados en la estimación. Un diseño basado en remuestreo —validación cruzada repetida o *bootstrap* sobre distintos conjuntos de entrenamiento— permitiría estimar la distribución empírica de los coeficientes, construir intervalos de confianza más robustos y comprobar la estabilidad del conjunto de variables seleccionadas entre réplicas (James et al., 2013).

En tercer lugar, el análisis empírico se ha desarrollado sobre una única base de datos histórica procedente de una plataforma concreta de préstamos. Aunque dicha muestra resulta amplia y adecuada para fines académicos, los resultados podrían variar al aplicarse sobre carteras bancarias diferentes, segmentos empresariales o entornos macroeconómicos distintos.

En cuarto lugar, la comparación entre modelos se ha centrado en un conjunto limitado de algoritmos representativos. Existen otros enfoques más avanzados, como XGBoost, LightGBM, redes neuronales profundas o modelos híbridos, que podrían ofrecer resultados adicionales de interés.

En quinto lugar, la evaluación se ha basado principalmente en métricas estadísticas estándar. En aplicaciones reales, sería conveniente incorporar también medidas económicas, como pérdidas esperadas, rentabilidad ajustada al riesgo o costes diferenciados de falsos positivos y falsos negativos.

Por último, aunque se ha discutido la cuestión de la interpretabilidad, no se han implementado de forma empírica herramientas específicas de inteligencia artificial explicable (XAI) como SHAP o LIME, cuya incorporación enriquecería futuras extensiones del trabajo.

A partir de los resultados obtenidos, pueden proponerse diversas líneas de investigación

futura. En primer lugar, sería de interés ampliar la comparación empírica incorporando modelos adicionales de machine learning, especialmente algoritmos de boosting y técnicas de aprendizaje profundo.

En segundo lugar, resultaría especialmente valioso integrar metodologías de Explainable Artificial Intelligence (XAI), con el objetivo de analizar hasta qué punto modelos complejos pueden alcanzar niveles de transparencia comparables a los modelos tradicionales.

En tercer lugar, futuras investigaciones podrían incorporar funciones de coste asimétricas que reflejen de forma más realista el impacto económico de los errores de clasificación en entidades financieras. Además, sería recomendable replicar el análisis en distintos contextos geográficos, regulatorios o macroeconómicos para evaluar la estabilidad externa de los resultados obtenidos.

Finalmente, una línea especialmente prometedora consiste en el desarrollo de marcos híbridos que combinen la interpretabilidad de los modelos lineales con la flexibilidad predictiva de técnicas avanzadas de machine learning.

## Referencias

- Abdou, H. A. and Pointon, J. (2011). Credit scoring, statistical techniques and evaluation criteria: a review of the literature. *Intelligent Systems in Accounting, Finance and Management*, 18(2-3):59–88.
- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716–723.
- Atance, D., Debón, A., and Navarro, E. (2020). A comparison of forecasting mortality models using resampling methods. *Mathematics*, 8(9):1550.
- Bagur, M. (2026). Tfg-credit-scoring. <https://github.com/marcbagur20/TFG-credit-scoring>. Repositorio de código consultado en abril de 2026.
- Bahnsen, A. C., Aouada, D., and Ottersten, B. (2014). Example-dependent cost-sensitive decision trees. In *2014 13th International Conference on Machine Learning and Applications*, pages 268–273. IEEE.
- Banasik, J., Crook, J. N., and Thomas, L. C. (1999). Not if but when will borrowers default. *Journal of the Operational Research Society*, 50(12):1185–1190.
- Basel Committee on Banking Supervision (2006). *International Convergence of Capital Measurement and Capital Standards: A Revised Framework - Comprehensive Version*. Bank for International Settlements, Basel.
- Basel Committee on Banking Supervision (2017). Basel iii: Finalising post-crisis reforms.
- Bishop, C. M. (1995). *Neural Networks for Pattern Recognition*. Oxford University Press.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J., Olshen, R., and Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Brown, I. and Mues, C. (2012). An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3):3446–3453.
- Bücker, M., Szepannek, G., Gosiewska, A., and Biecek, P. (2022). Transparency, auditability and explainability of machine learning models in credit scoring. *Journal of the Operational Research Society*, 73(1):70–90.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). Smote: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society. Series B (Methodological)*, 20(2):215–242.
- Dastile, X., Celik, T., and Potsane, M. (2020). Statistical and machine learning models in credit scoring: A systematic literature survey. *Applied Soft Computing*, 91:106263.
- Dong, G., Lai, K. K., and Yen, J. (2010). Credit scorecard based on logistic regression with random coefficients. *Procedia Computer Science*, 1(1):2463–2468.
- Draper, N. R. and Smith, H. (1998). Applied regression analysis. Technical report, New York.

- Efroymson, M. A. (1960). Multiple regression analysis. In Ralston, A. and Wilf, H. S., editors, *Mathematical Methods for Digital Computers*, pages 191–203. Wiley.
- European Union (2024a). Directive (eu) 2024/1619 of the european parliament and of the council of 31 may 2024 amending directive 2013/36/eu as regards supervisory powers, sanctions, third-country branches, and environmental, social and governance risks. Official Journal of the European Union, L, 19 June 2024.
- European Union (2024b). Regulation (eu) 2024/1623 of the european parliament and of the council of 31 may 2024 amending regulation (eu) no 575/2013 as regards requirements for credit risk, credit valuation adjustment risk, operational risk, market risk and the output floor. Official Journal of the European Union, L, 19 June 2024.
- Experian Decision Analytic (2026). Risk-based pricing: When does it work and when does it not? Documento Técnico / white paper. Acceso realizado el 2 de Febrero de 2026, a través de <https://es.scribd.com/document/381143880/Experian-Risk-Based-Pricing>.
- Fawcett, T. (2006). An introduction to roc analysis. *Pattern Recognition Letters*, 27(8):861–874.
- Finlay, S. (2012). *Credit scoring, response modeling, and insurance rating: a practical guide to forecasting consumer behavior*. Springer.
- Greene, W. H. (2012). *Econometric Analysis*. Pearson, 7 edition.
- Han, H., Wang, W.-Y., and Mao, B.-H. (2005). Borderline-smote: A new over-sampling method in imbalanced data sets learning. *Advances in Intelligent Computing*, pages 878–887.
- Hastie, T., Tibshirani, R., Friedman, J. H., and Friedman, J. H. (2009). *The elements of statistical learning: data mining, inference, and prediction*, volume 2. Springer.
- He, H. and Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9):1263–1284.
- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer, 2 edition.
- James, G., Witten, D., Hastie, T., Tibshirani, R., et al. (2013). *An introduction to statistical learning: with applications in R*, volume 103. Springer.
- James, G., Witten, D., Hastie, T., Tibshirani, R., and Taylor, J. (2023). Statistical learning. In *An introduction to statistical learning: With applications in Python*, pages 15–67. Springer.
- Kaggle, Inc. (2024). Kaggle.
- Kaufman, S., Rosset, S., and Perlich, C. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1–21.
- Kuhn, M. and Johnson, K. (2013). *Applied Predictive Modeling*. Springer, New York.
- Kumar, M. R. and Gunjan, V. K. (2020). Review of machine learning models for credit scoring analysis. *Ingeniería Solidaria*, 16(1):1–16.
- Matplotlib Development Team (2024). Matplotlib: Python plotting library.

- McCullagh, P. and Nelder, J. A. (1989). Binary data. In *Generalized linear models*, pages 98–148. Springer.
- Nelder, J. A. and Wedderburn, R. W. M. (1972). Generalized linear models. *Journal of the Royal Statistical Society. Series A*, 135(3):370–384.
- NumPy Developers (2024). Numpy: Fundamental package for scientific computing in python.
- Okam, H. (2024). *Prosper loan data*. Dominio Público a través de kaggle. Acceso realizado el 13 de Octubre de 2025 <https://www.kaggle.com/datasets/henryokam/prosper-loan-data>.
- pandas Development Team (2024). pandas: Python data analysis library.
- Prosper Marketplace, Inc. (2012). Annual report (form 10-k) for the fiscal year ended december 31, 2011. Technical report, U.S. Securities and Exchange Commission, Washington, D.C. Disponible en EDGAR: <https://www.sec.gov/Archives/edgar/data/0001416265/000141626512000198/p10k12d31d2011.htm>.
- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464.
- scikit-learn Developers (2024). scikit-learn: Machine learning in python.
- Shi, S., Tse, R., Luo, W., D’Addona, S., and Pau, G. (2022). Machine learning-driven credit risk: a systemic review. *Neural Computing and Applications*, 34(17):14327–14339.
- Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3):289–310.
- statsmodels Developers (2024). statsmodels: Statistical modeling in python.
- Svolba, G. (2006). *Data preparation for analytics using SAS*. SAS Institute.
- Thomas, L. C. (2009). *Consumer credit models: Pricing, profit and portfolios*. OUP Oxford.



Universidad  
de Alcalá

2025/2026